Модели машинного обучения без учителя (Unsupervised Learning)

PIERIAN DATA

Обучение без учителя (Unsupervised Learning)

- Пришло время узнать об алгоритмах машинного обучения без учителя - Unsupervised Learning!
- Это будет смена парадигмы по сравнению с нашей предыдущей работой с алгоритмами обучения с учителем, Supervised Learning.

Обучение без учителя (Unsupervised Learning)

- Если Data Science можно представить себе как сочетание искусства и математической науки, то обучение без учителя (unsupervised learning) больше тяготеет к области искусства.

Обучение без учителя (Unsupervised Learning)

- Обучение с учителем (Supervised Learning)
  - При помощи **размеченных (labeled)** данных предсказать значение для новых данных (регрессия или классификация).
- Обучение без учителя (Unsupervised Learning)
  - При помощи **неразмеченных (unlabeled)** данных найти закономерности в данных, кластеры или существенные компоненты.

Обучение без учителя (Unsupervised Learning)

- Обучение без учителя (Unsupervised Learning):
  - Кластеризация:
    - С помощью признаков сгруппировать строки в отдельные кластеры.
  - Уменьшение размерности:
    - С помощью признаков перейти к меньшему количеству компонент в данных.

Обучение без учителя (Unsupervised Learning)

- Смена парадигмы при переходе от обучения с учителем к обучению без учителя:
  - **Метрики для обучения с учителем не подходят для обучения без учителя!**
  - Как мы можем сравниваться с правильными ответами, если у нас нет известных значений целевой переменной?

Обучение без учителя (Unsupervised Learning)

- Вместо таких метрик как RMSE и Accuracy, нам нужно как-то по-другому оценивать работу моделей обучения без учителя.
- Даже само понятие “насколько хорошо работает модель” придётся сформулировать по-другому!

Обучение без учителя (Unsupervised Learning)

- Давайте посмотрим, как выглядят шаги этапов работ по машинному обучению, когда речь идёт об обучении без учителя (Unsupervised Learning).

Этапы работ по машинному обучению

Окружающий мир

→ Сырые данные

PIERIAN DATA

Этапы работ по машинному обучению

Окружающий мир

Сырые данные

Сенсоры,
Опросы,
Симуляции,
Эксперименты,
Использование данных и т.д.

Этапы работ по машинному обучению

Окружающий мир

→ Сырые данные → Сбор и хранение данных

SQL базы данных.
CSV файлы, Excel,
Облачное хранение

Этапы работ по машинному обучению

Окружающий мир

→ Сбор и хранение данных

Этапы работ по машинному обучению

Окружающий мир

→ Сбор и хранение данных → Очистка и организация данных

Этапы работ по машинному обучению

Окружающий мир

→ Сбор и хранение данных → Очистка и организация данных → Исследование данных

PIERIAN DATA

Этапы работ по машинному обучению

Окружающий мир

→ Сбор и хранение данных → Очистка и организация данных → Исследование данных → Модели Машинного Обучения

Supervised Learning:
Сделать предсказание

Unsupervised Learning:
Найти закономерности в данных

PIERIAN DATA

Этапы работ по машинному обучению

Окружающий мир

Сбор и хранение данных

Очистка и организация данных

Исследование данных

Кластеризация

Unsupervised Learning: Найти закономерности в данных

Уменьшение размерности

PIERIAN DATA

Этапы работ по машинному обучению

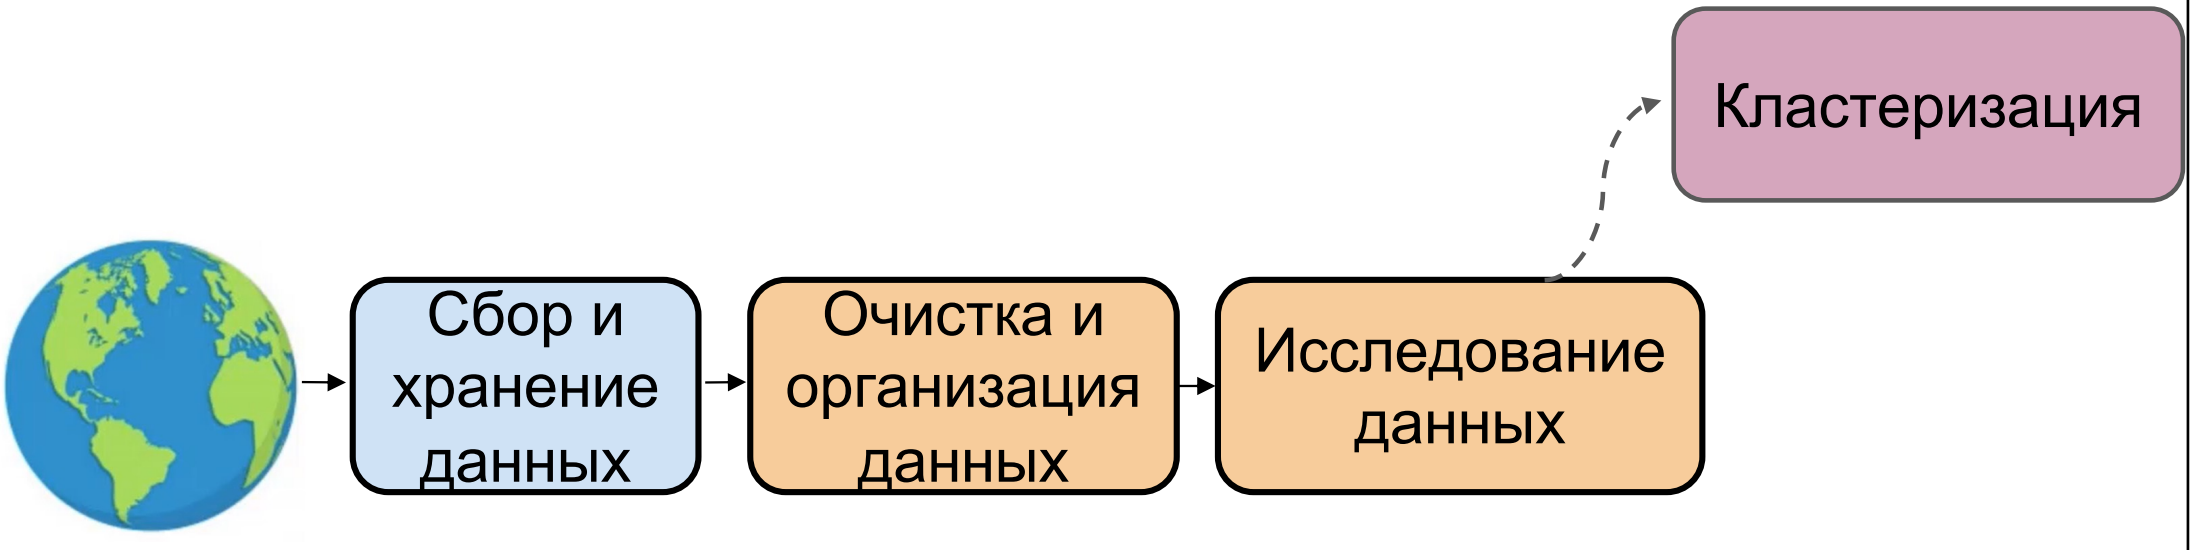

Окружающий мир

Кластеризация: если у нас есть неразмеченные данные, то можем ли мы собрать похожие точки данных вместе, чтобы “найти” возможные значения целевой переменной для кластеров?

Этапы работ по машинному обучению

Окружающий мир

Сбор и хранение данных → Очистка и организация данных → Исследование данных → Уменьшение размерности

Уменьшение размерности: если у нас есть неразмеченные данные, то можем ли мы уменьшить количество признаков, собирая их в новые компоненты? Могут ли эти новые компоненты дать нам новые знания о данных?

Обучение без учителя (Unsupervised Learning)

- Мы начнём с изучения методов кластеризации данных, таких как K-Means и Иерархическая кластеризация, а затем перейдём к уменьшению размерности.
- Попутно мы узнаем о методах интерпретации результатов моделей, поскольку оценка работы модели - это более тонкий вопрос для обучения без учителя.

Обучение без учителя (Unsupervised Learning)

- Какие вопросы следует иметь ввиду:
  - Что означает фраза, что мы можем “найти” значения целевой переменной (label) с помощью кластеризации данных?
  - Как мы можем оценить работу модели, не имея значений целевой переменной?
  - Могут ли комбинации признаков содержать полезную информацию о данных?

Давайте начнём!