DBSCAN

DBSCAN

- DBSCAN =**D**ensity-**b**ased **s**patial **c**lustering of **a**pplications with **n**oise.
- Это алгоритм для кластеризации данных и поиска выбросов (outliers).

DBSCAN

- Обзор раздела:
  - Как работает DBSCAN на интуитивном уровне
  - Сравнение DBSCAN и K-Means Clustering
  - Гиперпараметры DBSCAN – теория
  - Гиперпараметры DBSCAN – пишем код
  - Проверочные задания по поиску выбросов
  - Решения для проверочных заданий

Давайте начнём!

DBSCAN

Теория и интуиция

PIERIAN DATA

DBSCAN

- DBSCAN = Density-based spatial clustering of applications with noise.
- Давайте кратко обсудим историю этого алгоритма, и затем посмотрим на интуитивном уровне, как он работает.

DBSCAN

- 1972: Роберт Ф. Линг опубликовал очень похожий алгоритм в работе "Теория и построение k-кластеров», со временем выполнения $O(n^3)$.
- Если количество точек **n** растёт, то время работы алгоритма растёт как $\mathbf{n^3}$!

DBSCAN

- 1996: Мартин Эстер, Ганс-Петер Кригель, Ёрг Сандер и Сяовэй Су предложили современную версию алгоритма DBSCAN со временем $O(n^2)$.
- 2014: DBSCAN получил награду “test of time” (“проверено временем”) на ведущей конференции по интеллектуальному анализу данных SIGKDD.

DBSCAN

- Вопросы для обсуждения:
  - Как работает DBSCAN?
  - Плюсы и минусы DBSCAN?
  - Как этот алгоритм работает с выбросами и шумом в данных?

DBSCAN

- Ключевые идеи алгоритма DBSCAN
  - DBSCAN использует плотность точек для назначения номеров кластеров.
  - Это позволяет находить такие кластеры, которые не под силу другим алгоритмам.

DBSCAN

- Рассмотрим следующий набор данных:

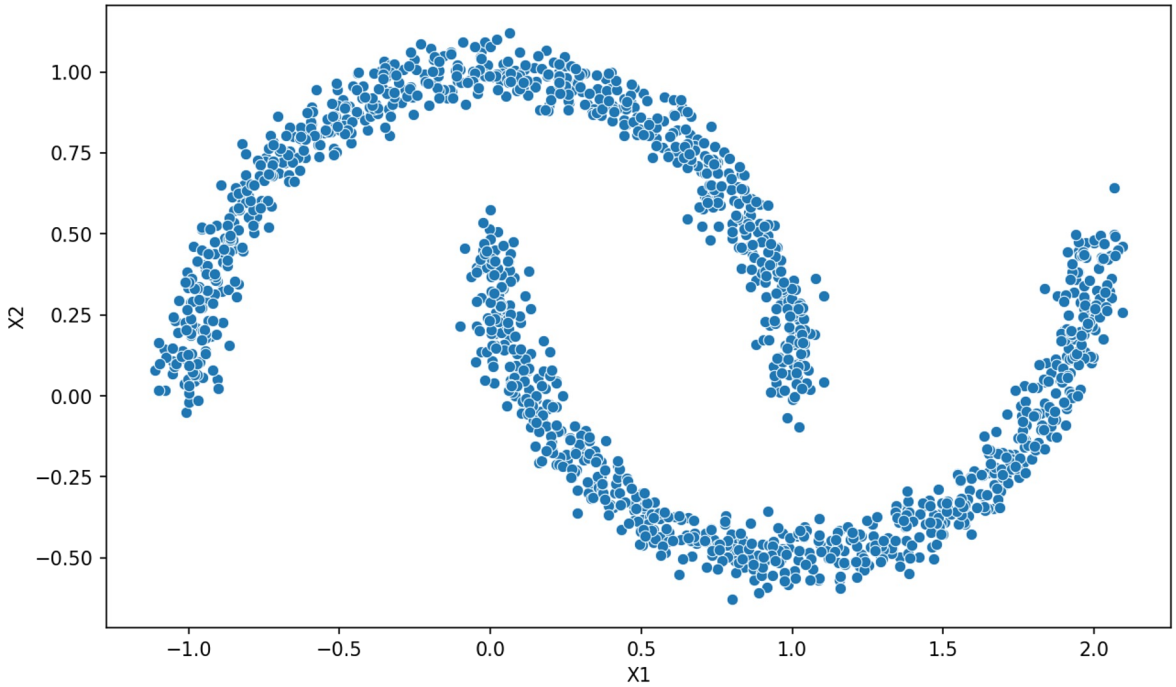

DBSCAN

- Два кластера в виде “луны” (“moon”) :

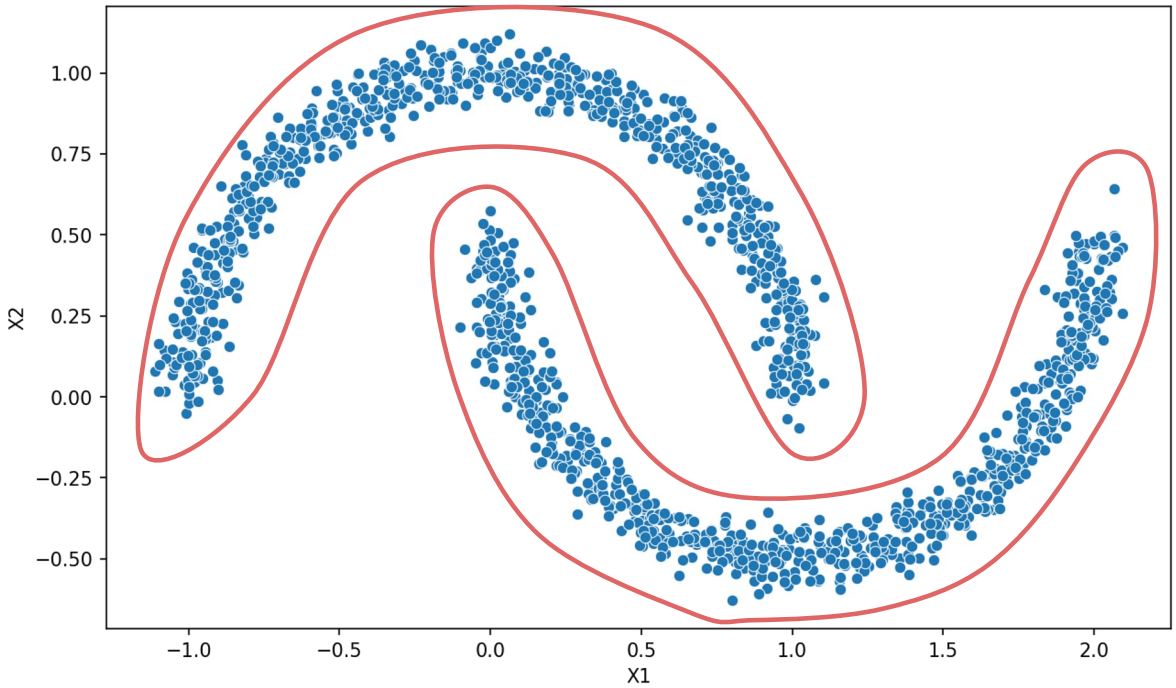

DBSCAN

- Сложности кластеризации на основе расстояния:

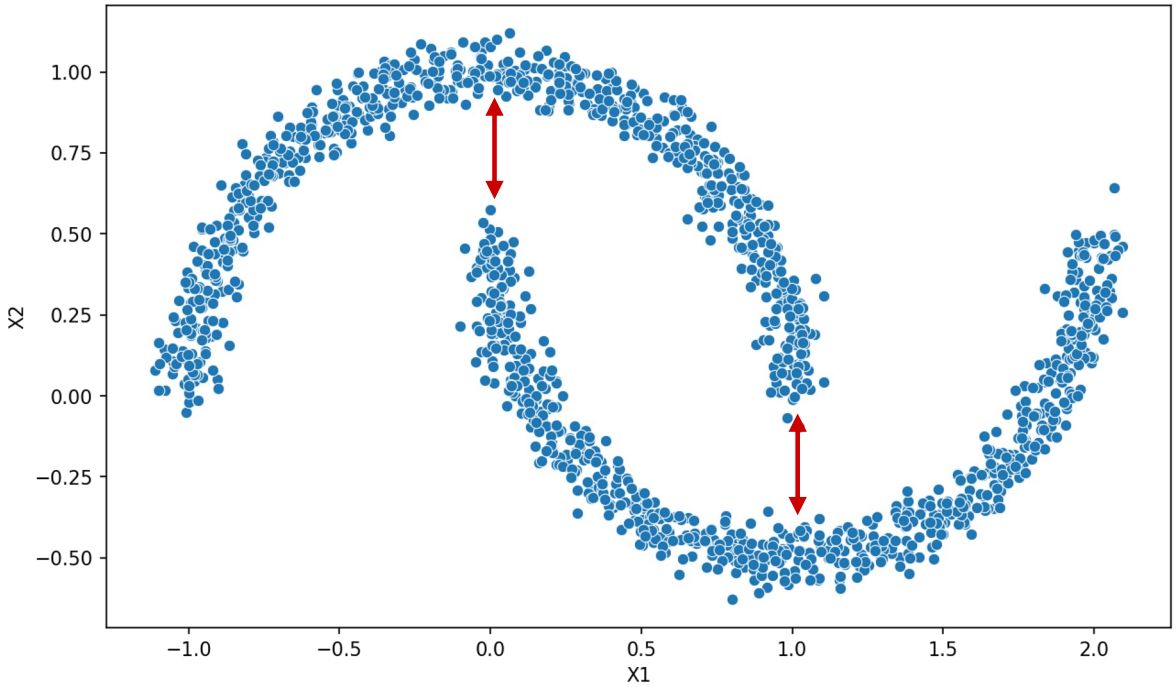

DBSCAN

- Сложности кластеризации на основе расстояния:

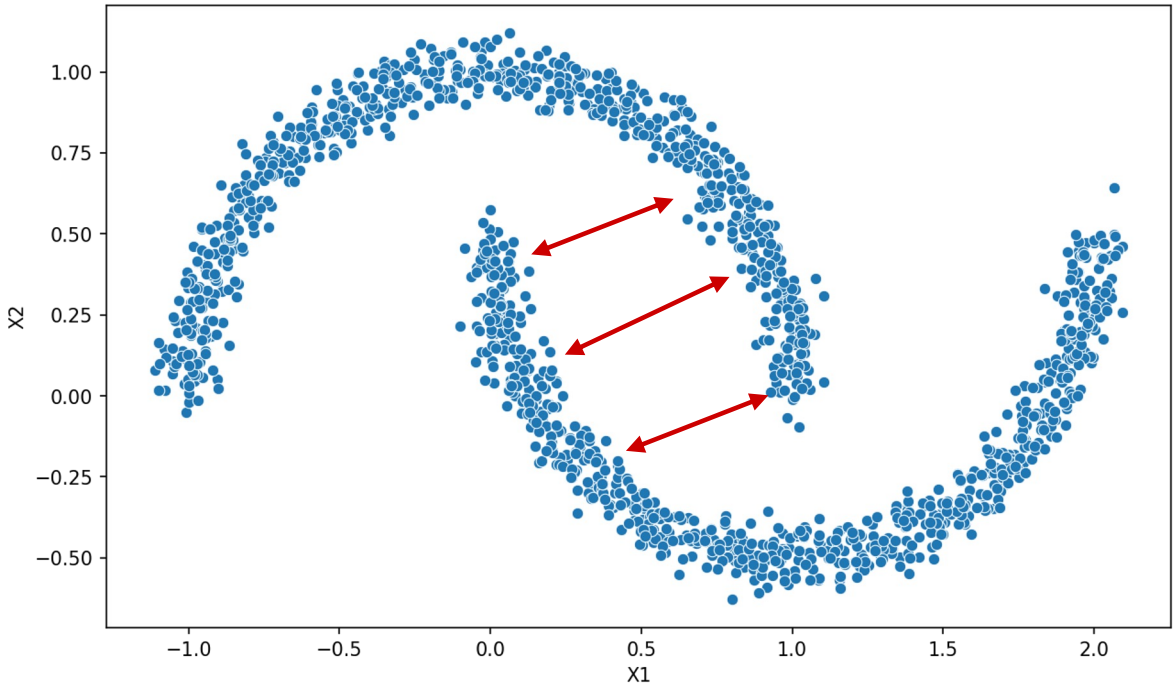

DBSCAN

- Результат кластеризации К-средних (K-Means):

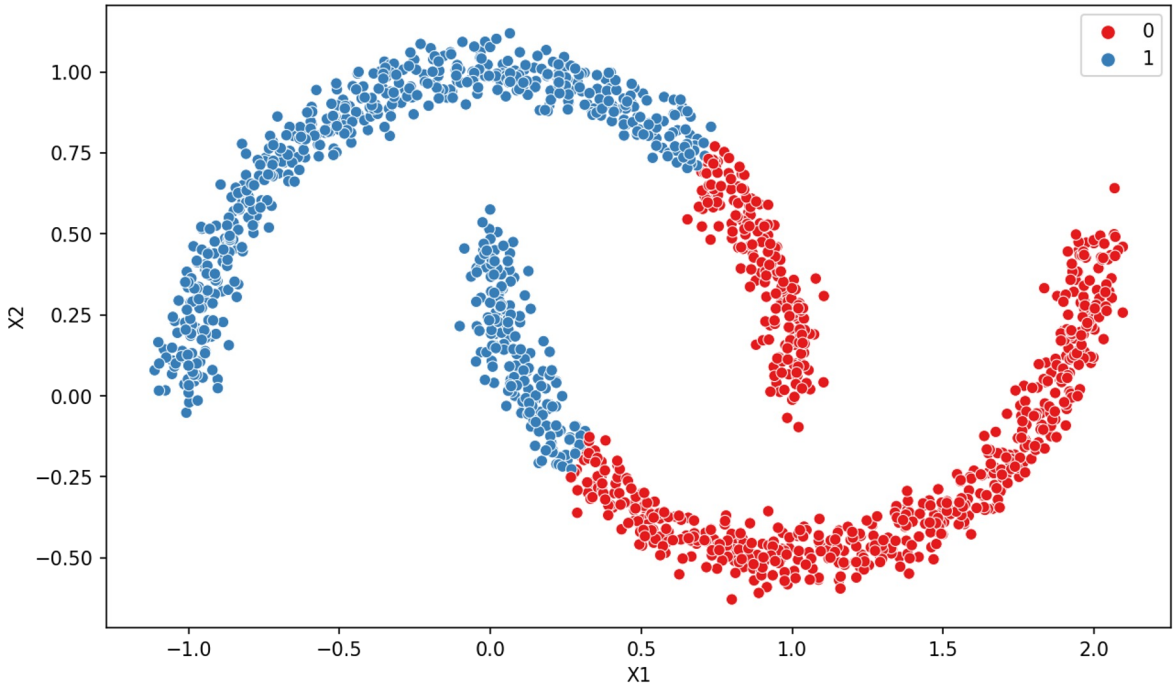

DBSCAN

- Результат кластеризации DBSCAN:

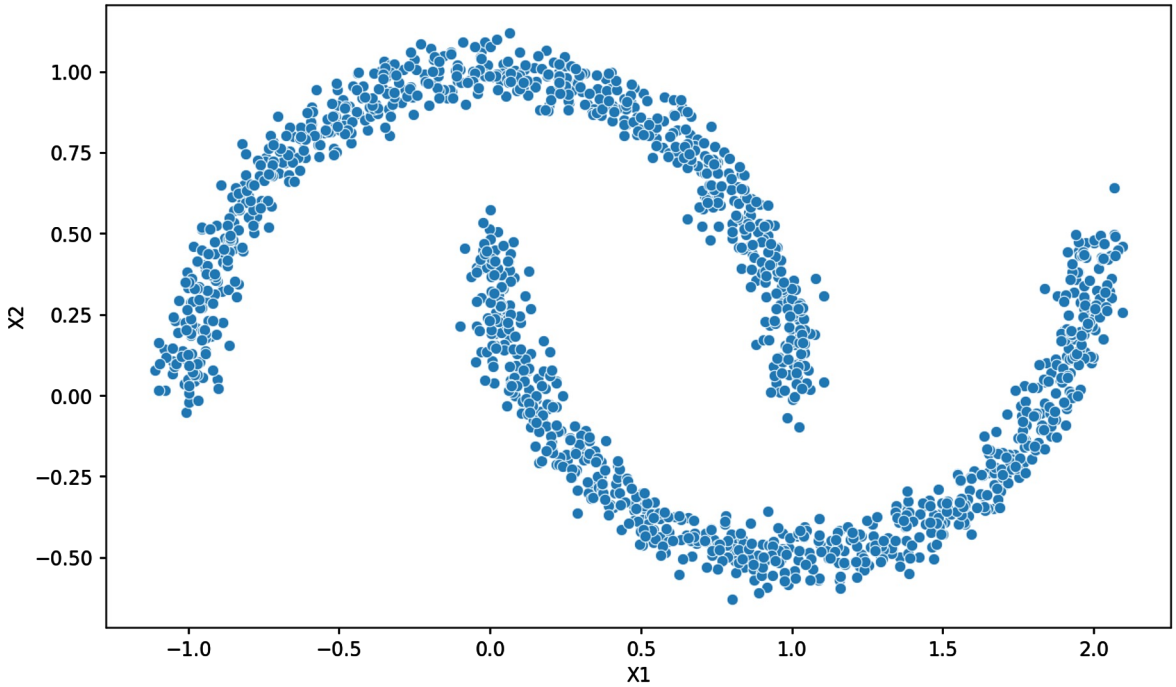

DBSCAN

- Результат кластеризации DBSCAN:

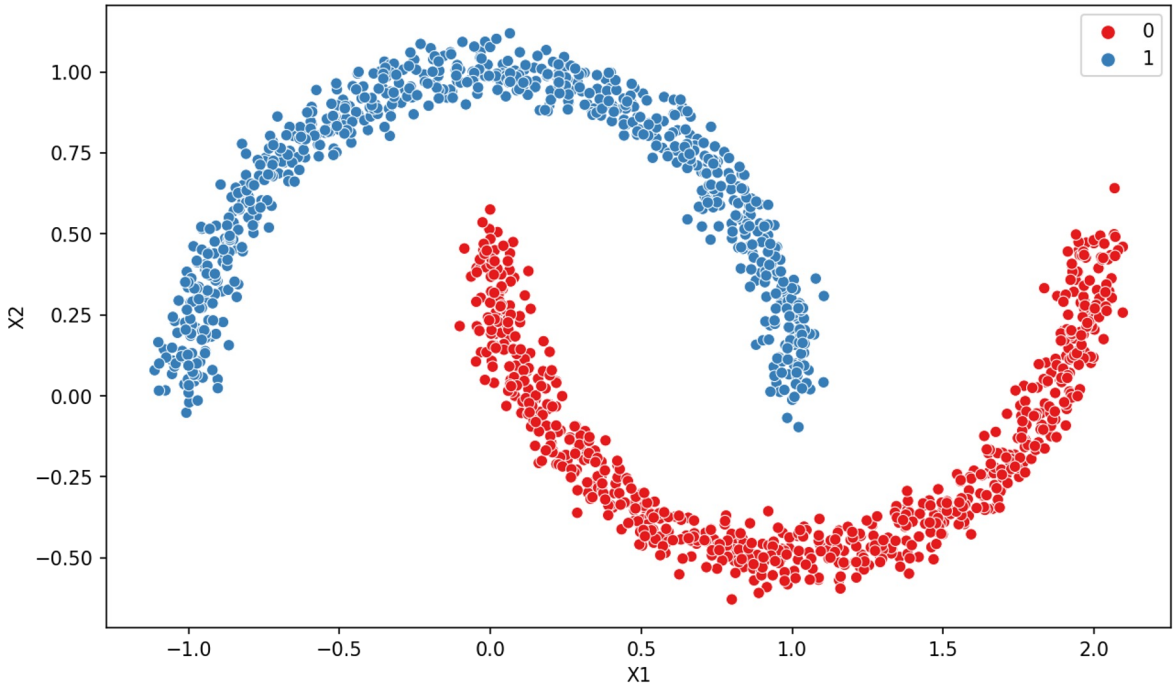

DBSCAN

- DBSCAN выполняет итерации по точкам, используя два гиперпараметра (эпсилон и минимальное количество точек) для назначения кластеров.
- В отличие от K-Means, в качестве основной метрики используется плотность точек.

DBSCAN

- Основные гиперпараметры DBSCAN:
  - Эпсилон:
    - Расстояние (окрестность) вокруг точки.
  - Минимальное количество точек:
    - Минимальное количество точек в эпсилон-окрестности точки.

DBSCAN

- Типы точек в алгоритме DBSCAN:
  - Core
  - Border
  - Outlier

DBSCAN

- Типы точек в алгоритме DBSCAN:
  - Core
  - Border
  - Outlier

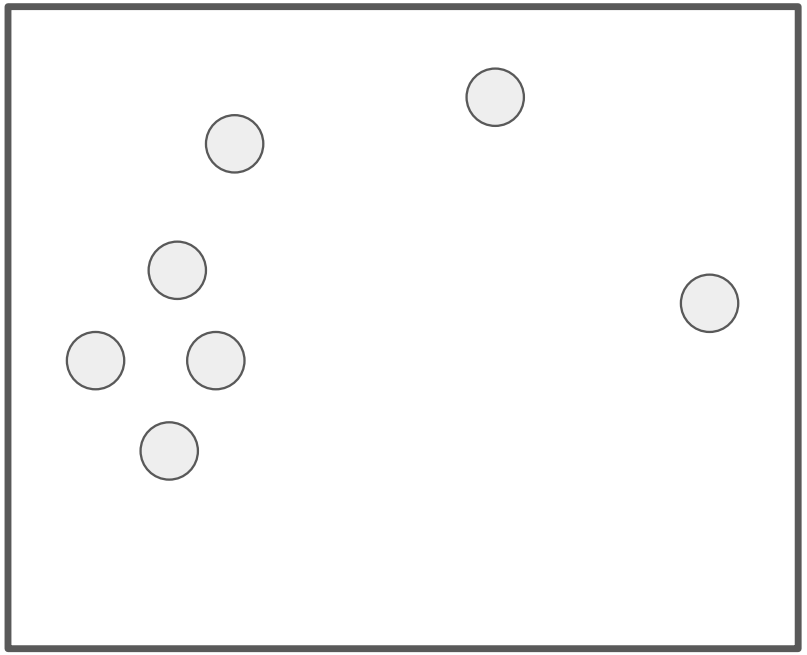

DBSCAN

- Типы точек в алгоритме DBSCAN:
  - Core

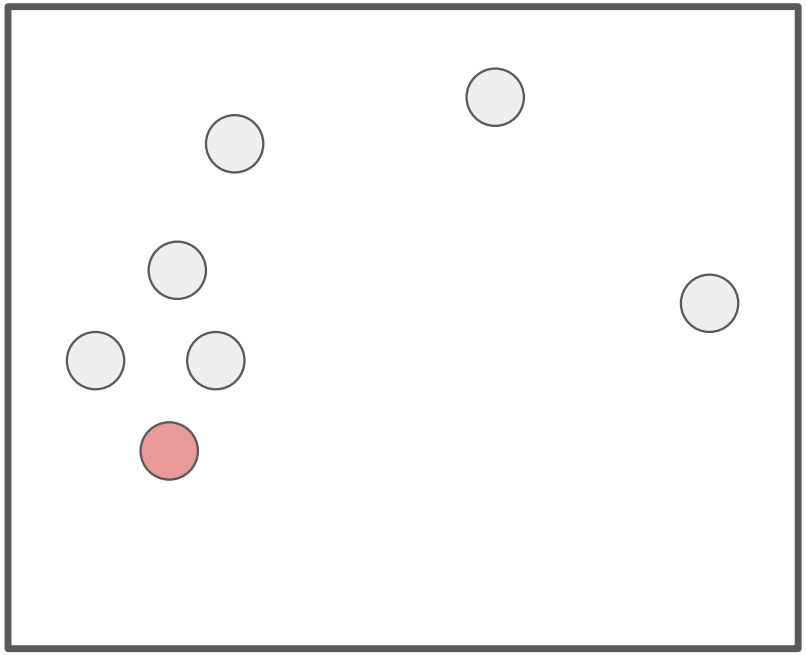

DBSCAN

- Типы точек в алгоритме DBSCAN:
  - Core

ε = 1 и Min Points = 2

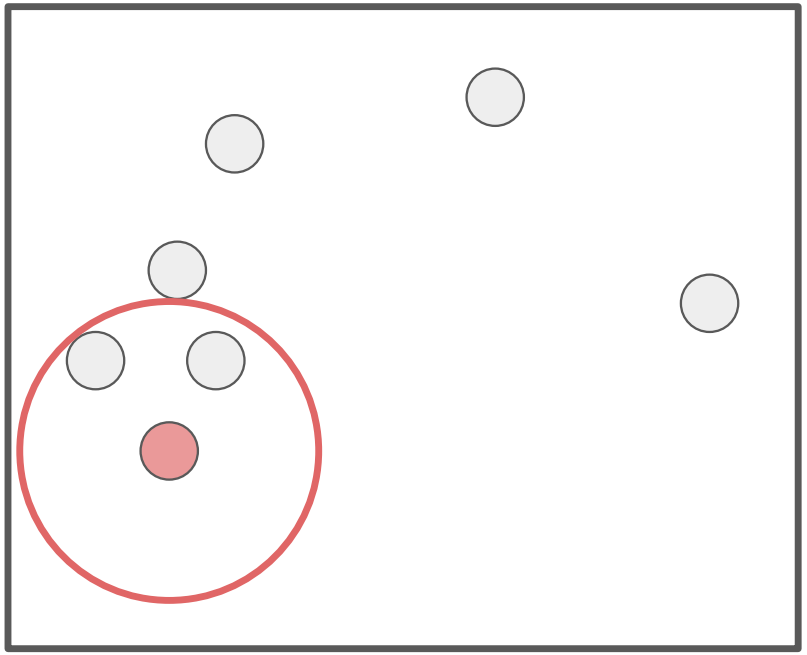

DBSCAN

- Типы точек в алгоритме DBSCAN:
  - Core

ε = 1 и Min Points = 2

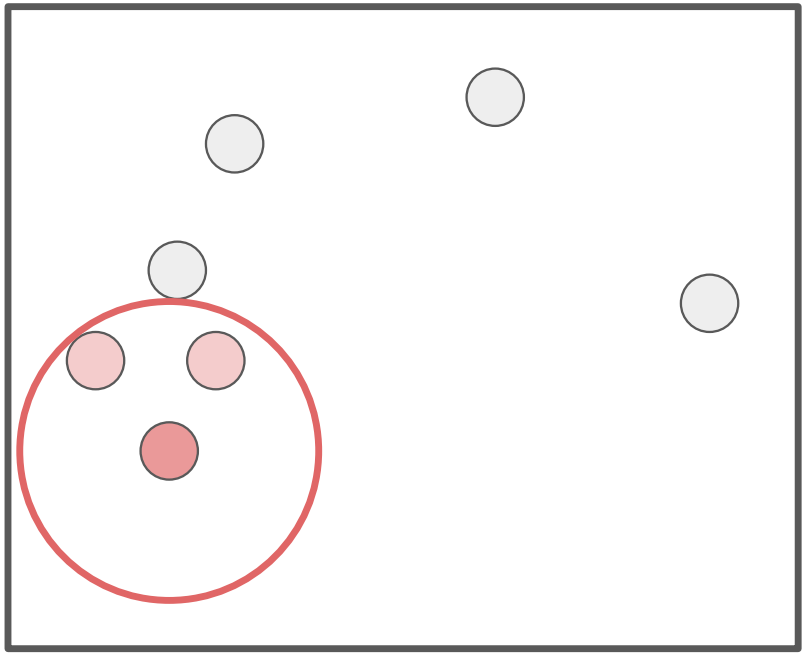

DBSCAN

- Типы точек в алгоритме DBSCAN:
  - Core
    - Точка, имеющая минимальное количество точек в эпсилон-окрестности.

ε = 1 и Min Points = 2

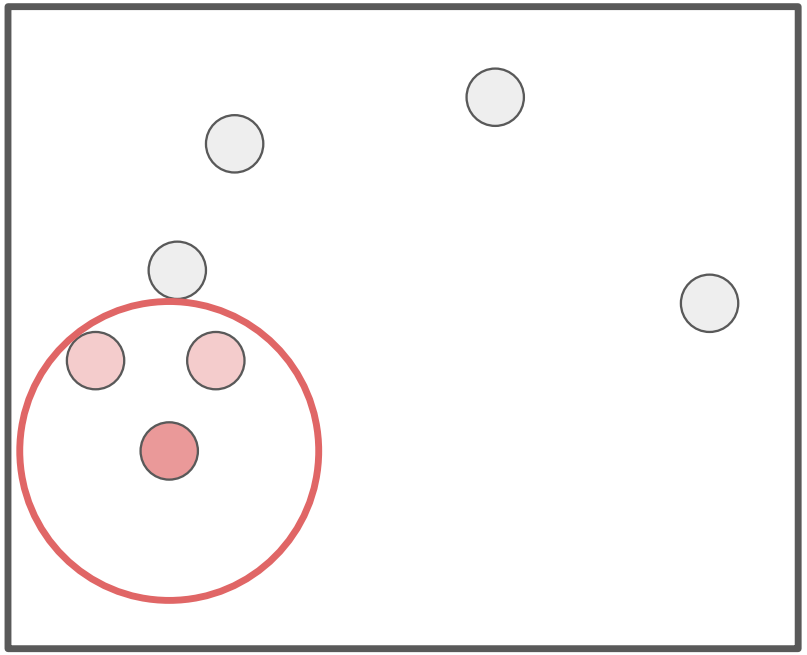

DBSCAN

- Типы точек в алгоритме DBSCAN:
  - Core
    - Точка, имеющая минимальное количество точек в эпсилон-окрестности.

ε = 1 и Min Points = 2

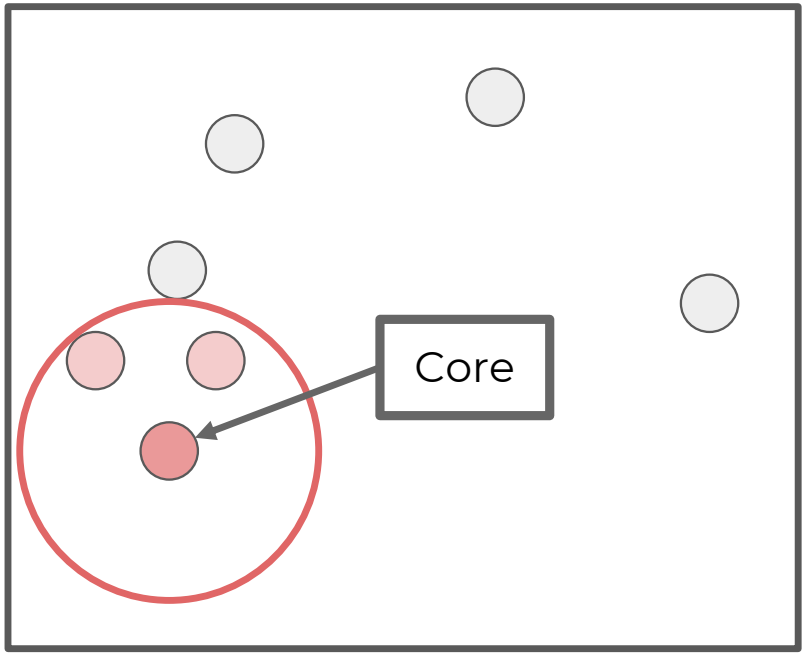

DBSCAN

- Типы точек в алгоритме DBSCAN:
  - Core
    - Точка, имеющая минимальное количество точек в эпсилон-окрестности (включая саму точку).

ε = 1 и Min Points = 3

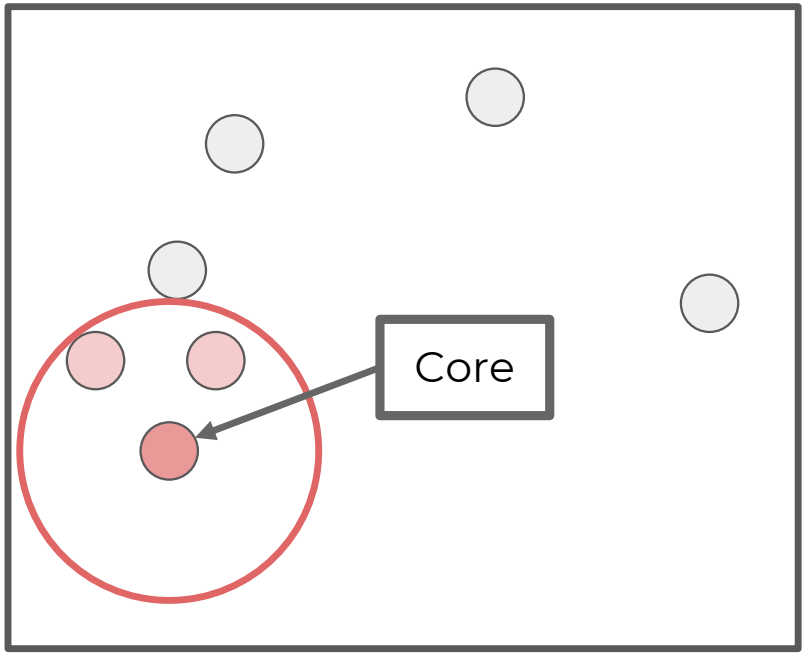

DBSCAN

- Типы точек в алгоритме DBSCAN:
  - Border:
    - Находится в эпсилон-окрестности точки core, но не имеет минимальное количество точек в своей окрестности.

ε = 1 и Min Points = 3

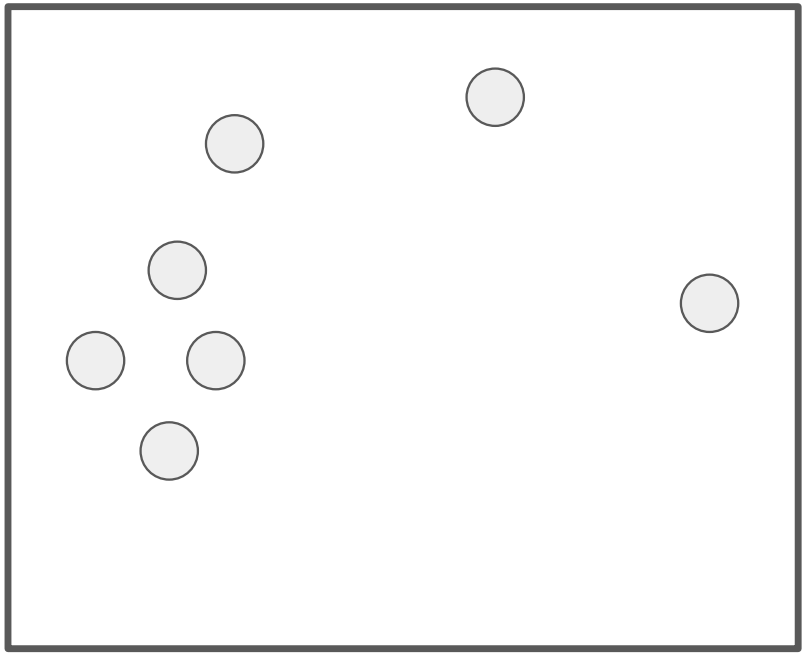

DBSCAN

- Типы точек в алгоритме DBSCAN:
  - Border:
    - Находится в эпсилон-окрестности точки core, но не имеет минимальное количество точек в своей окрестности.

ε = 1 и Min Points = 3

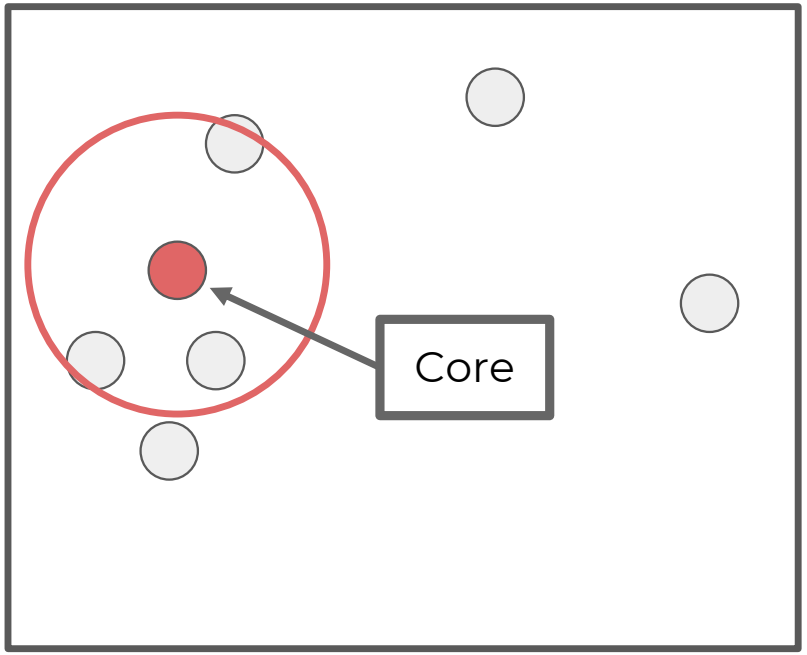

DBSCAN

- Типы точек в алгоритме DBSCAN:
  - Border:
    - Находится в эпсилон-окрестности точки core, но не имеет минимальное количество точек в своей окрестности.

ε = 1 и Min Points = 3

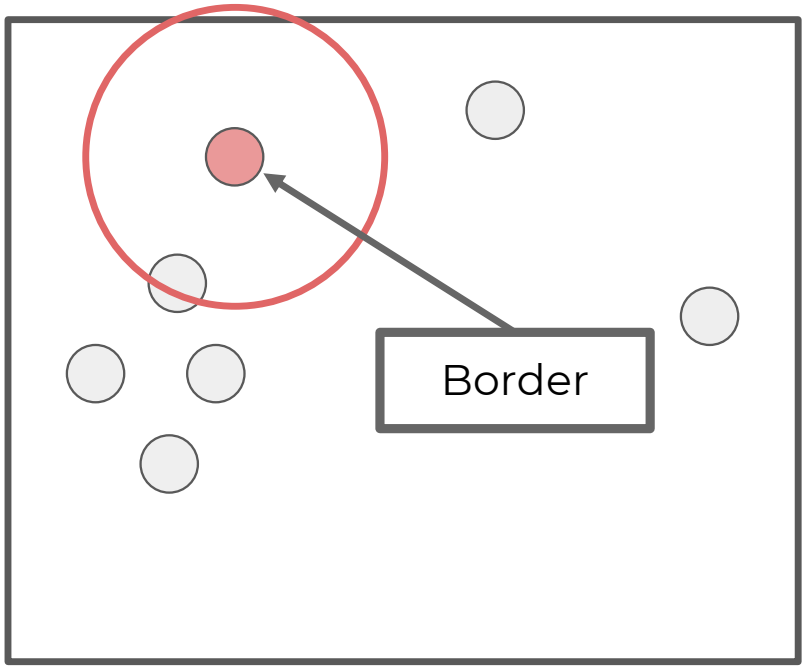

DBSCAN

- Типы точек в алгоритме DBSCAN:
  - Border:
    - Находится в эпсилон-окрестности точки core, но не имеет минимальное количество точек в своей окрестности.

ε = 1 и Min Points = 3

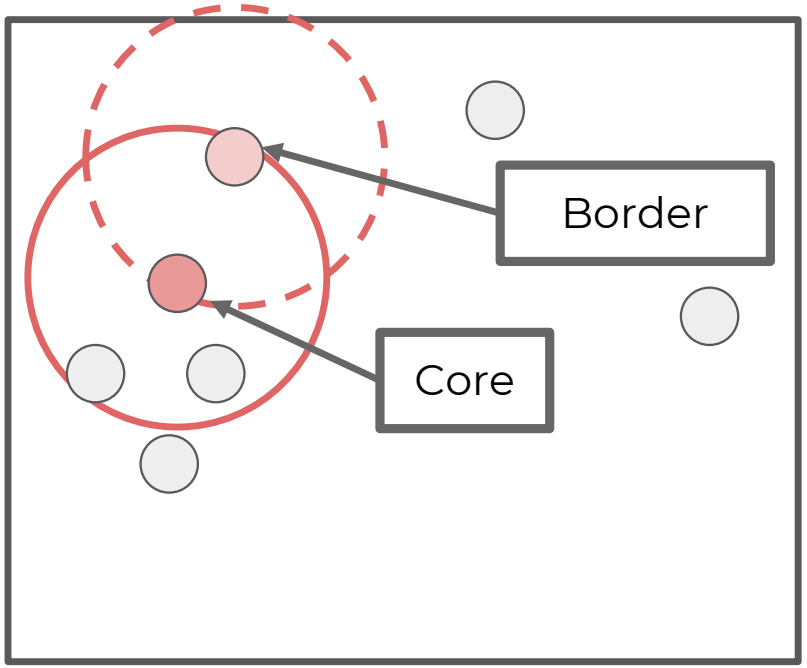

DBSCAN

- Типы точек в алгоритме DBSCAN:
  - Outlier:
    - До этой точки нельзя “добраться” при назначении кластеров другим точкам.

ε = 1 и Min Points = 3

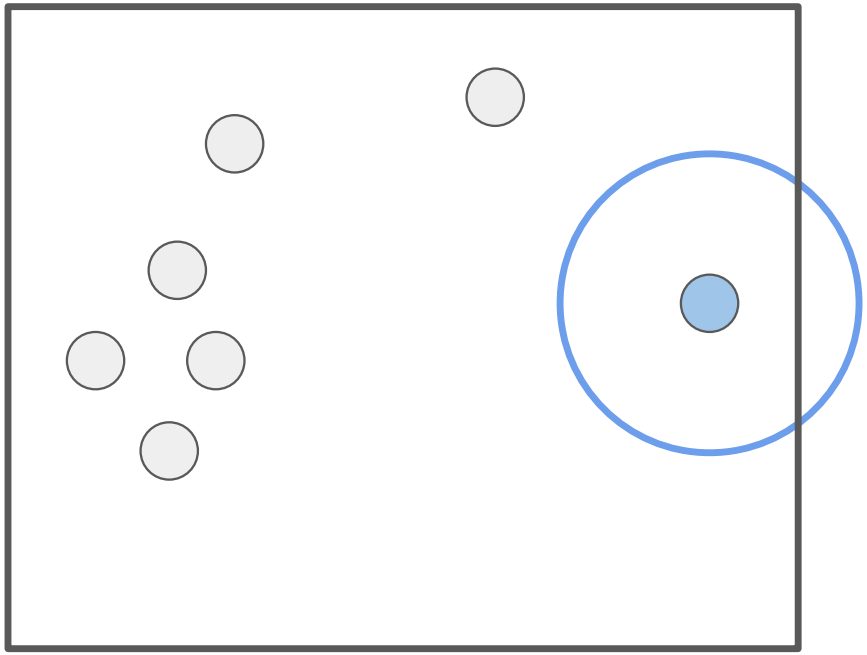

DBSCAN

- Позднее мы подробнее обсудим окрестности, эпсилон и минимальное количество точек.
- Давайте обсудим процесс присвоения номеров кластеров в алгоритме DBSCAN.

DBSCAN

- Шаги алгоритма DBSCAN:
  - Берём случайную точку, не принадлежащую ни одному кластеру.
  - Определяем тип точки (core/border/outlier).
  - Если найдена точка core, то все точки в её окрестности помещаются в кластер точки core
  - Повторяем для всех точек - все точки будут либо в кластерах , либо выбросами (outlier).

DBSCAN

- Давайте посмотрим очень полезную визуализацию этого процесса!

DBSCAN

Пример кода

DBSCAN

- Мы сравним DBSCAN и K-Means clustering на некоторых наборах данных
- Это позволит нам сравнить подход на основе плотности точек (DBSCAN) и подход на основе расстояния между точками (K-Means).

DBSCAN

Ключевые гиперпараметры

DBSCAN

- Основные гиперпараметры DBSCAN (повторение):
  - Эпсилон:
    - Расстояние (окрестность) вокруг точки.
  - Минимальное количество точек:
    - Минимальное количество точек в эпсилон-окрестности точки, чтобы считать точку как **core**.

DBSCAN

- Меняя эти гиперпараметры, мы:
  - Меняем количество кластеров.
  - Влияем на определение точек-выбросов

DBSCAN

- Пример данных:

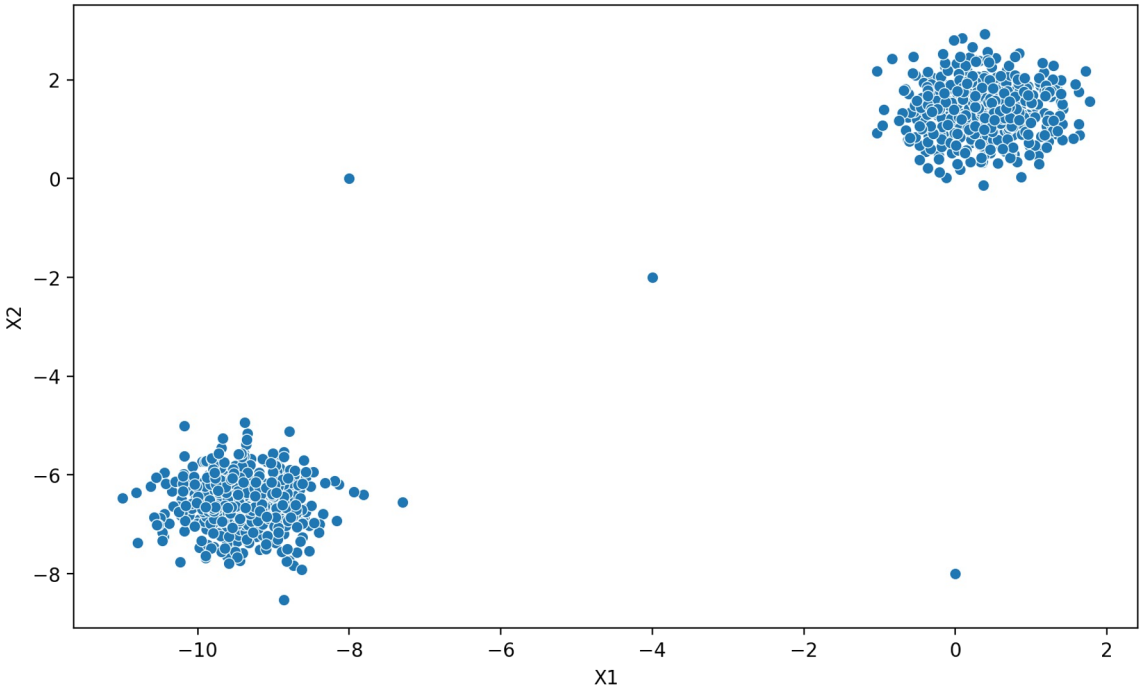

DBSCAN

- Пример данных:

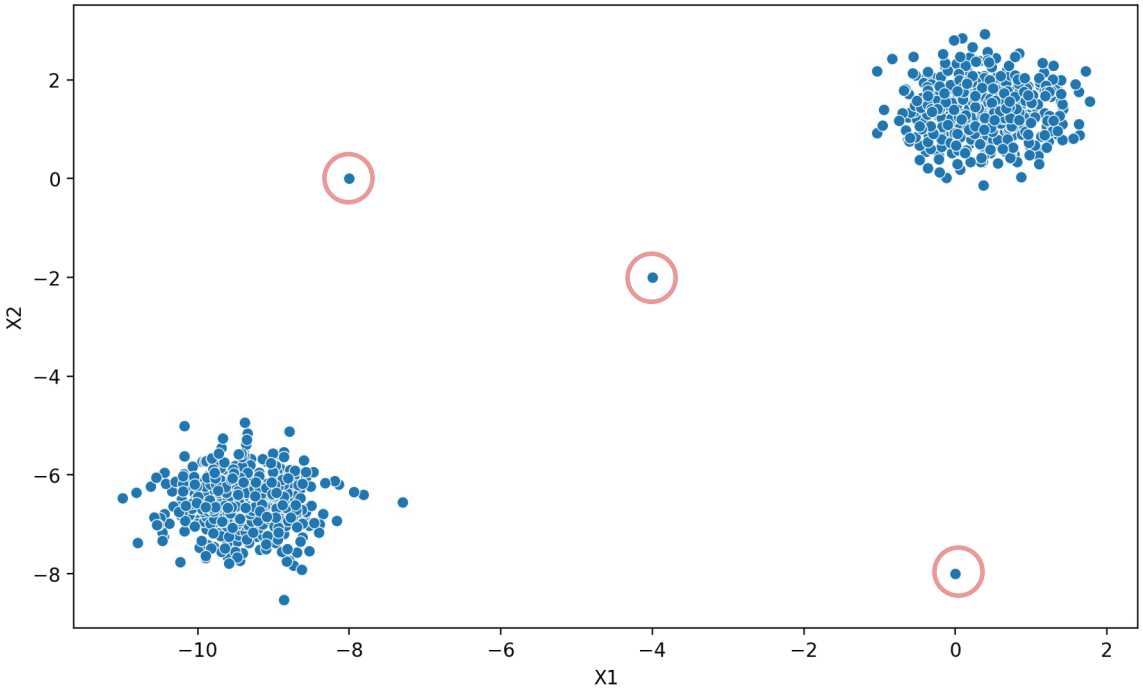

DBSCAN

- Результаты DBSCAN:

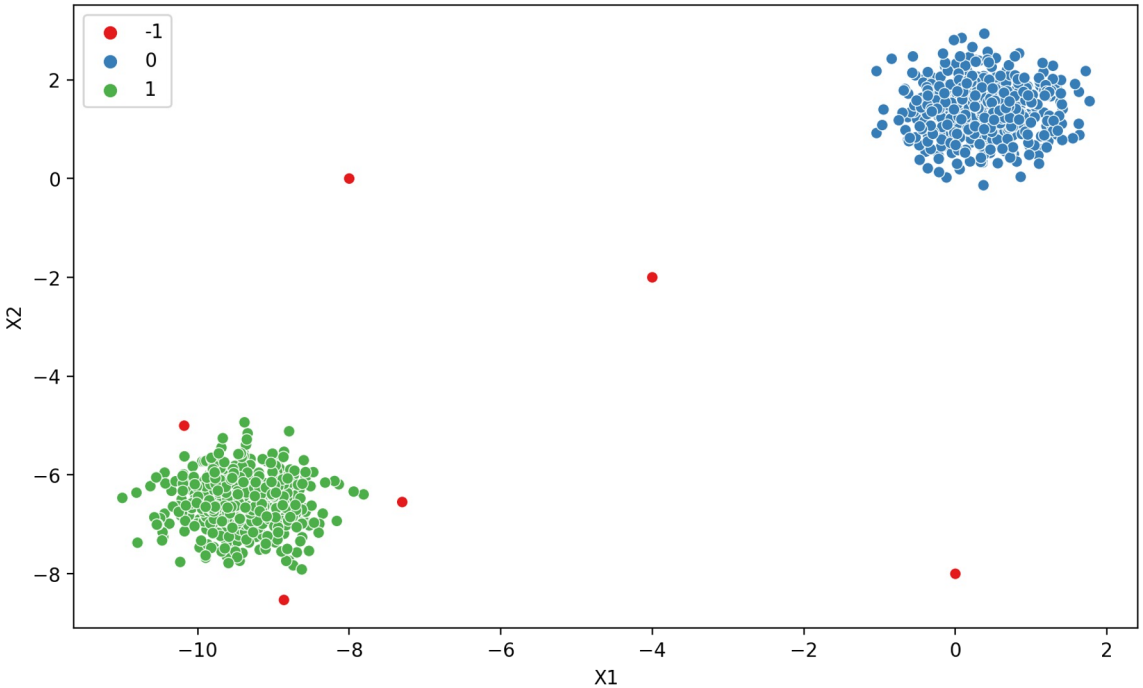

DBSCAN

- Результаты DBSCAN:

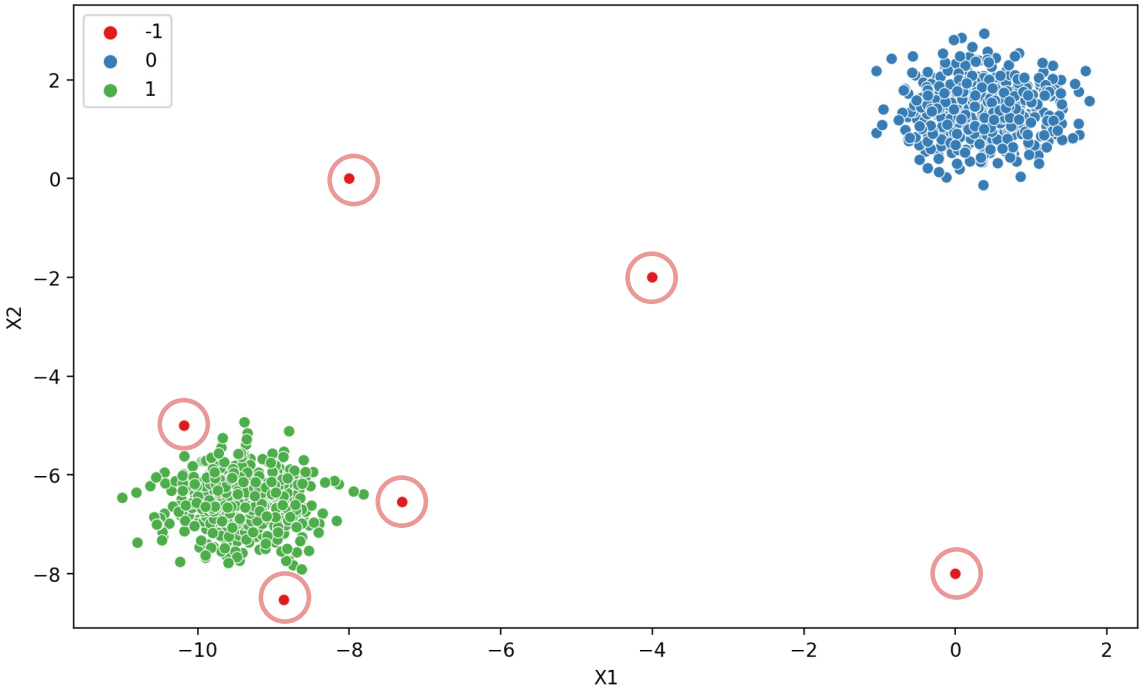

DBSCAN

- Результаты DBSCAN:

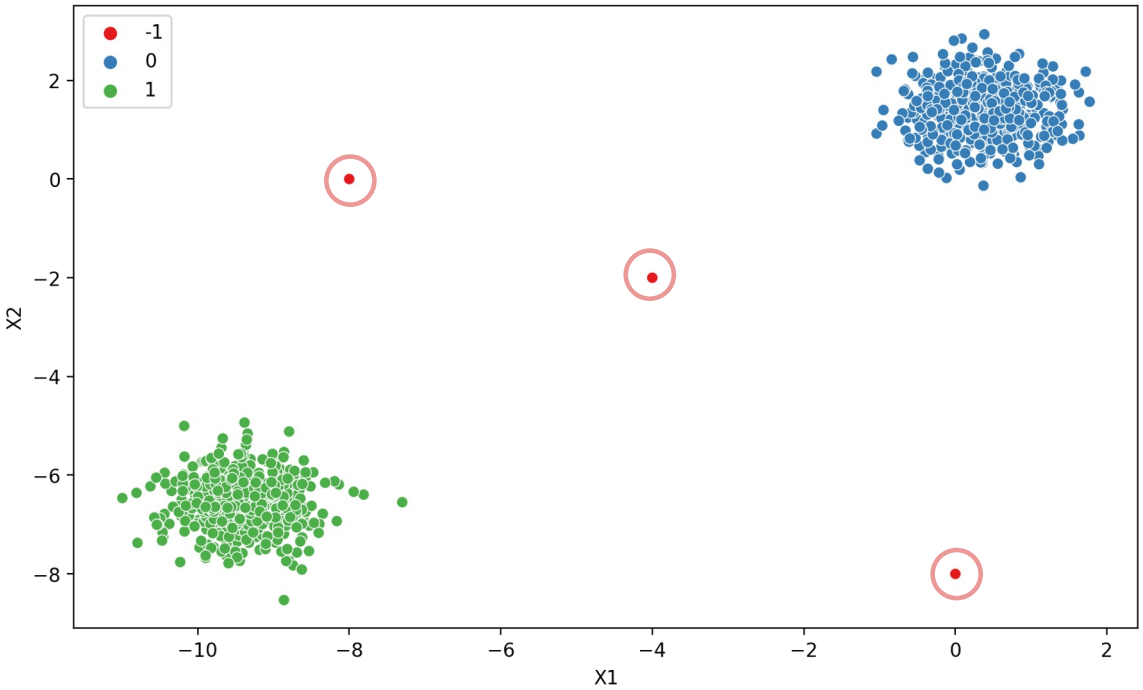

DBSCAN

- Как работает эпсилон:
  - Увеличение эпсилон позволяет бОльшему количеству точек быть core-точками, в итоге мы получаем также больше border-точек, а также меньше точек-выбросов.
  - Если эпсилон огромный, то все точки будут в окрестности друг друга и попадут в один кластер!

DBSCAN

- Как работает эпсилон:
  - Уменьшая эпсилон, получается что меньше точек находятся “близко” друг к другу, и мы получаем больше разных кластеров.
  - Если эпсилон крайне мало, то мы не сможем дотянуться до соседних точек!

DBSCAN

- Как можно найти значение эпсилон:
  - Попробовать несколько моделей DBSCAN с различными эпсилон, измеряя:
    - Количество кластеров
    - Количество точек-выбросов (outliers)
    - Процент точек-выбросов (outliers)

DBSCAN

- Как можно найти значение эпсилон:
  - Очень сильно зависит от конкретных данных и предметной области.
  - Нужны знания и интуиция о количестве кластеров и допустимом проценте точек-выбросов.

DBSCAN

- Метод “локтя” для разных значений эпсилон:

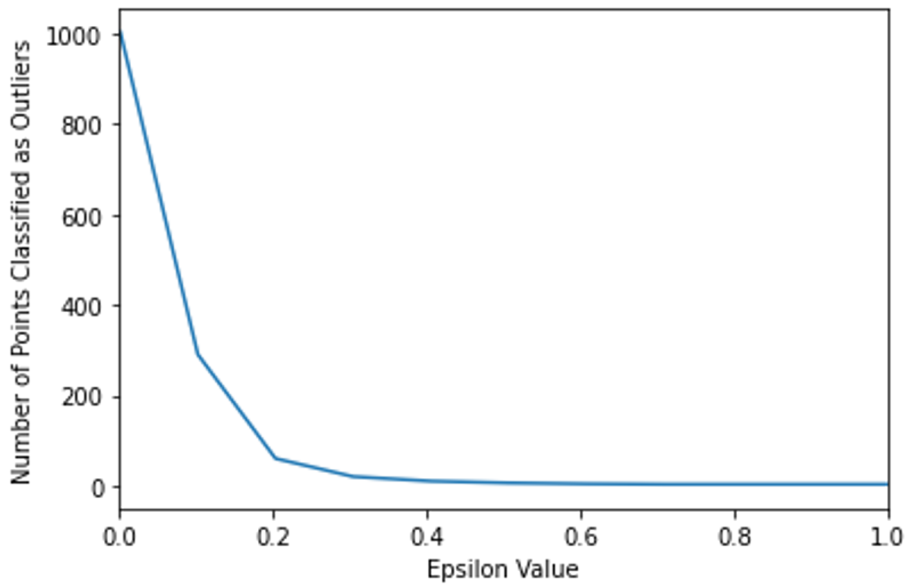

DBSCAN

- Минимальное количество точек:
  - Минимальное количество точек в эпсилон-окрестности точки (включая саму точку), чтобы считать точку как **core**.

DBSCAN

- Как работает параметр “мин. кол-во точек”:
  - Увеличивая количество точек, которое требуется для обозначения core-точки, мы получаем больше точек-выбросов.

DBSCAN

- Как работает параметр “мин. кол-во точек”:
  - Увеличивая количество точек, которое требуется для обозначения core-точки, мы получаем больше точек-выбросов.
  - Если мин. кол-во точек очень близко к общему количеству точек, то скорее всего все точки будут точками-выбросами

DBSCAN

- Как выбрать параметр “мин. кол-во точек” :
  - Протестировать различные значения, и померить количество/процент выбросов:

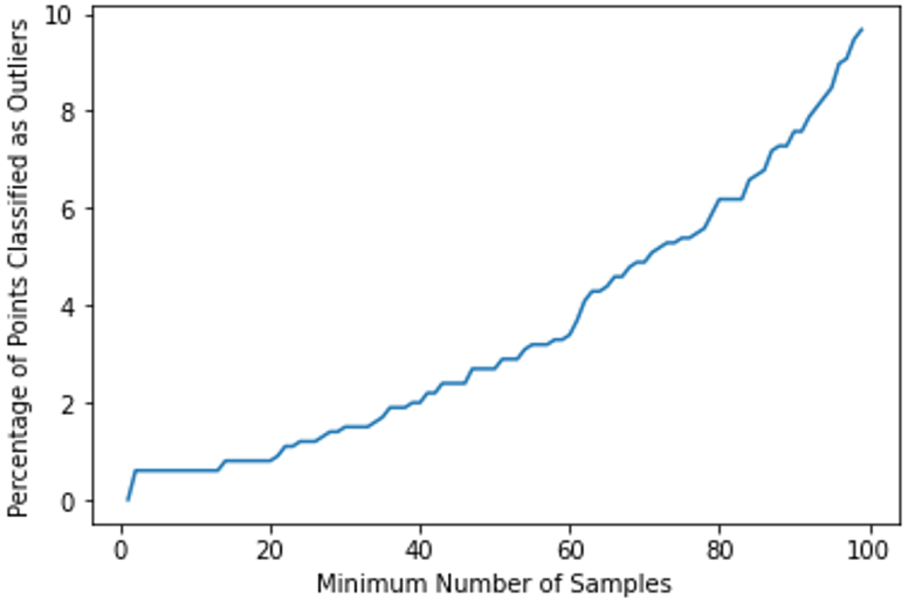

DBSCAN

- Замечание:
  - Иногда можно уменьшить мин.кол-во точек, чтобы создать отдельные кластеры вместо точек-выбросов.

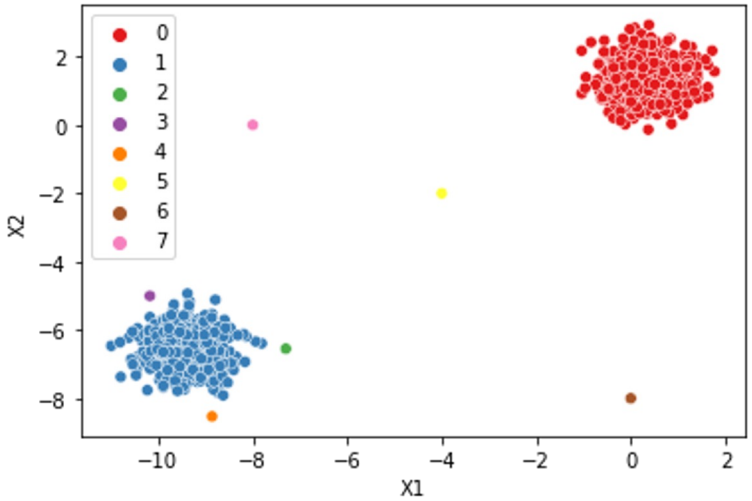

DBSCAN

- Далее мы исследуем эти гиперпараметры на конкретных примерах, написав код в Python!

DBSCAN

Поиск гиперпараметров

DBSCAN

Обзор проверочных заданий

PIERIAN DATA

DBSCAN

Решения