Метод главных компонент (Principal Component Analysis)

PIERIAN DATA

Метод главных компонент

- Ранее мы обсуждали алгоритмы обучения без учителя (unsupervised learning) для задач кластеризации данных.
- Теперь мы перейдём к алгоритмам обучения без учителя, выполняющих уменьшение размерности (dimension reduction).

Метод главных компонент

- Зачем уменьшать размерность?
  - Представьте данные с 30+ признаками. Как Вы поймёте, какие из них ключевые?
  - Визуализация и анализ данных становятся менее эффективны, когда количество признаков растёт.

Метод главных компонент

- Результаты уменьшения размерности:
  - Понимание того, какие признаки объясняют большую часть вариации в данных.
  - Помогают людям лучше понимать большие и сложные наборы данных, особенно с помощью визуализации данных.

Метод главных компонент

- Важное замечание:
  - Уменьшение размерности не выбирает только некоторые из имеющихся признаков.
  - Мы создаём новые признаки на основе комбинаций уже существующих признаков, в некоторых пропорциях.

Метод главных компонент

- Обзор раздела
  - Теория метода главных компонент.
  - Вручную реализуем этот метод на примере.
  - Посмотрим реализацию в Scikit-Learn.
  - Проверочные задания
  - Решения для проверочных заданий

Давайте начнём!

Метод главных компонент

Теория – Часть 1

PIERIAN DATA

Метод главных компонент

- 1901: Карл Пирсон опубликовал работу “On Lines and Planes of Closest Fit to Systems of Points in Space”.
- Пирсон был протеже Фрэнсиса Гальтона, и в его честь был назван коэффициент корреляции Пирсона.

Метод главных компонент

- 1933: Математик и экономист Гарольд Хоттелинг независимо разработал и опубликовал метод главных компонент (Principal Component Analysis) в своей работе “Analysis of a complex of statistical variables into principal components”.

Метод главных компонент

- В работе Хотеллинга очень хорошо описана цель метода главных компонент:
    - Взять сложный набор данных, и найти в нём главные компоненты.

Метод главных компонент

- Результаты уменьшения размерности:
  - Уменьшить размерность в данных
  - Понять, какие признаки объясняют большую часть вариации в данных.

Метод главных компонент

- Уменьшение размерности

	mean radius	mean smoothness
0	17.99	0.11840
1	20.57	0.08474
2	19.69	0.10960
3	11.42	0.14250
4	20.29	0.10030
...	...	...
564	21.56	0.11100
565	20.13	0.09780
566	16.60	0.08455
567	20.60	0.11780
568	7.76	0.05263

Метод главных компонент

- Уменьшение размерности

	mean radius	mean smoothness
0	17.99	0.11840
1	20.57	0.08474
2	19.69	0.10960
3	11.42	0.14250
4	20.29	0.10030
...	...	...
564	21.56	0.11100
565	20.13	0.09780
566	16.60	0.08455
567	20.60	0.11780
568	7.76	0.05263

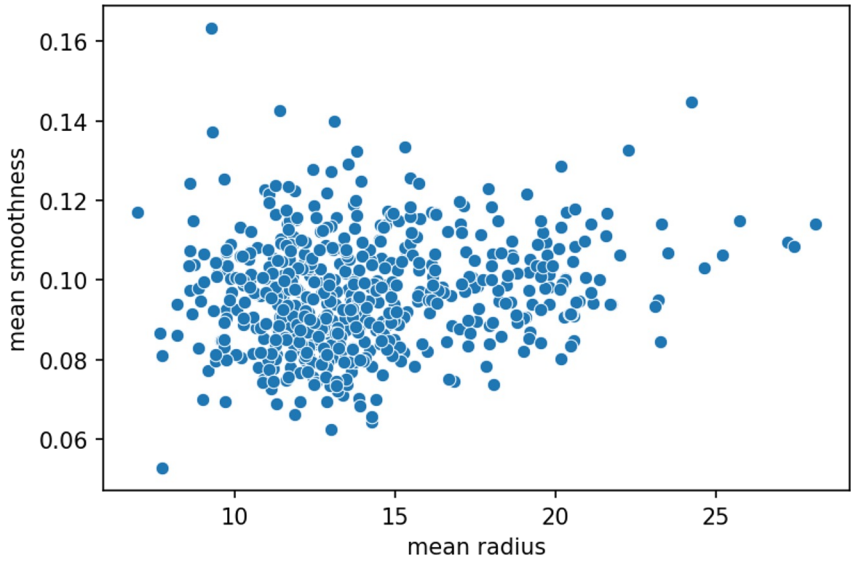

Метод главных компонент

- Уменьшение размерности

	mean radius	mean smoothness	mean symmetry
0	17.99	0.11840	0.2419
1	20.57	0.08474	0.1812
2	19.69	0.10960	0.2069
3	11.42	0.14250	0.2597
4	20.29	0.10030	0.1809
...	...	...	...
564	21.56	0.11100	0.1726
565	20.13	0.09780	0.1752
566	16.60	0.08455	0.1590
567	20.60	0.11780	0.2397
568	7.76	0.05263	0.1587

Метод главных компонент

- Уменьшение размерности

	mean radius	mean smoothness	mean symmetry
0	17.99	0.11840	0.2419
1	20.57	0.08474	0.1812
2	19.69	0.10960	0.2069
3	11.42	0.14250	0.2597
4	20.29	0.10030	0.1809
...	...	...	...
564	21.56	0.11100	0.1726
565	20.13	0.09780	0.1752
566	16.60	0.08455	0.1590
567	20.60	0.11780	0.2397
568	7.76	0.05263	0.1587

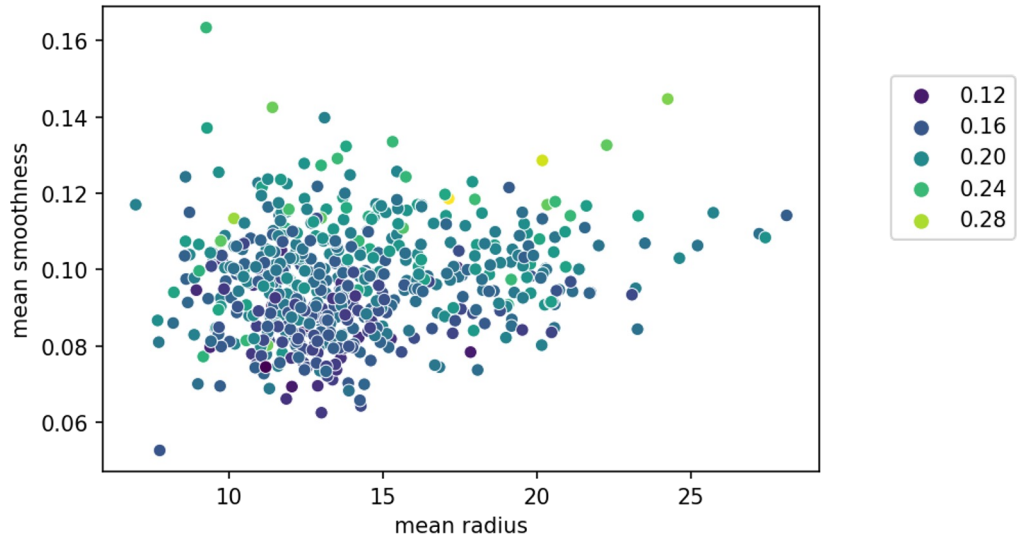

Метод главных компонент

- Уменьшение размерности

	mean radius	mean texture	mean perimeter	mean area	mean smoothness	mean compactness	mean concavity	mean concave points	mean symmetry	mean fractal dimension	...
0	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.30010	0.14710	0.2419	0.07871	...
1	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.08690	0.07017	0.1812	0.05667	...
2	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.19740	0.12790	0.2069	0.05999	...
3	11.42	20.38	77.58	386.1	0.14250	0.28390	0.24140	0.10520	0.2597	0.09744	...
4	20.29	14.34	135.10	1297.0	0.10030	0.13280	0.19800	0.10430	0.1809	0.05883	...
...	...	...	...	...	...	...	...	...	...	...	...
564	21.56	22.39	142.00	1479.0	0.11100	0.11590	0.24390	0.13890	0.1726	0.05623	...
565	20.13	28.25	131.20	1261.0	0.09780	0.10340	0.14400	0.09791	0.1752	0.05533	...
566	16.60	28.08	108.30	858.1	0.08455	0.10230	0.09251	0.05302	0.1590	0.05648	...
567	20.60	29.33	140.10	1265.0	0.11780	0.27700	0.35140	0.15200	0.2397	0.07016	...
568	7.76	24.54	47.92	181.0	0.05263	0.04362	0.00000	0.00000	0.1587	0.05884	...

569 rows × 30 columns

Метод главных компонент

- Уменьшение размерности

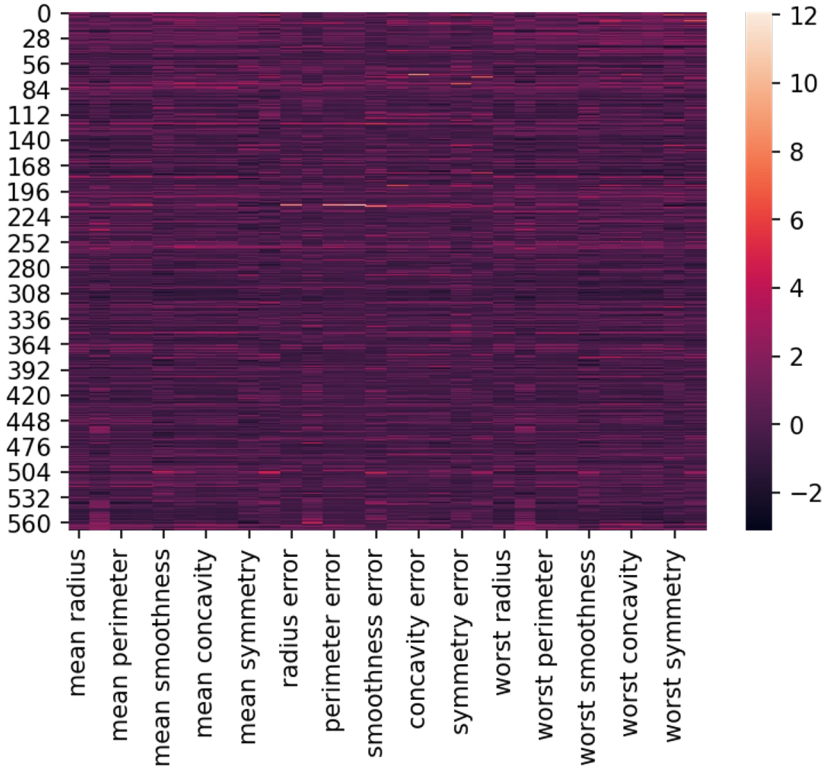

PIERIAN DATA

Метод главных компонент

- Уменьшение размерности
  - Помогает визуализировать и лучше понимать сложные наборы данных.
  - Помогает упростить данные для применения в других алгоритмах машинного обучения.
    - Сначала уменьшаем размерность, затем применяем другой алгоритм.

Метод главных компонент

- Уменьшение размерности
  - Уменьшает количество признаков до нужного количества, выполняя **трансформацию** признаков.
  - Это отличается от простого выбора только некоторых признаков.

Метод главных компонент

- Объяснение вариативности (Variance Explained)

Метод главных компонент

- Объяснение вариативности (Variance Explained)
  - Мы уже видели, что некоторые признаки могут быть важнее других признаков.
  - В задаче определения цены дома – размер дома намного лучше объясняет цену дома, чем цвет фасада дома.

Метод главных компонент

- Объяснение вариативности (Variance Explained)
  - Мы можем измерить пропорцию, в которой признаки отвечают за вариативность в данных.

Метод главных компонент

- Объяснение вариативности (Variance Explained)

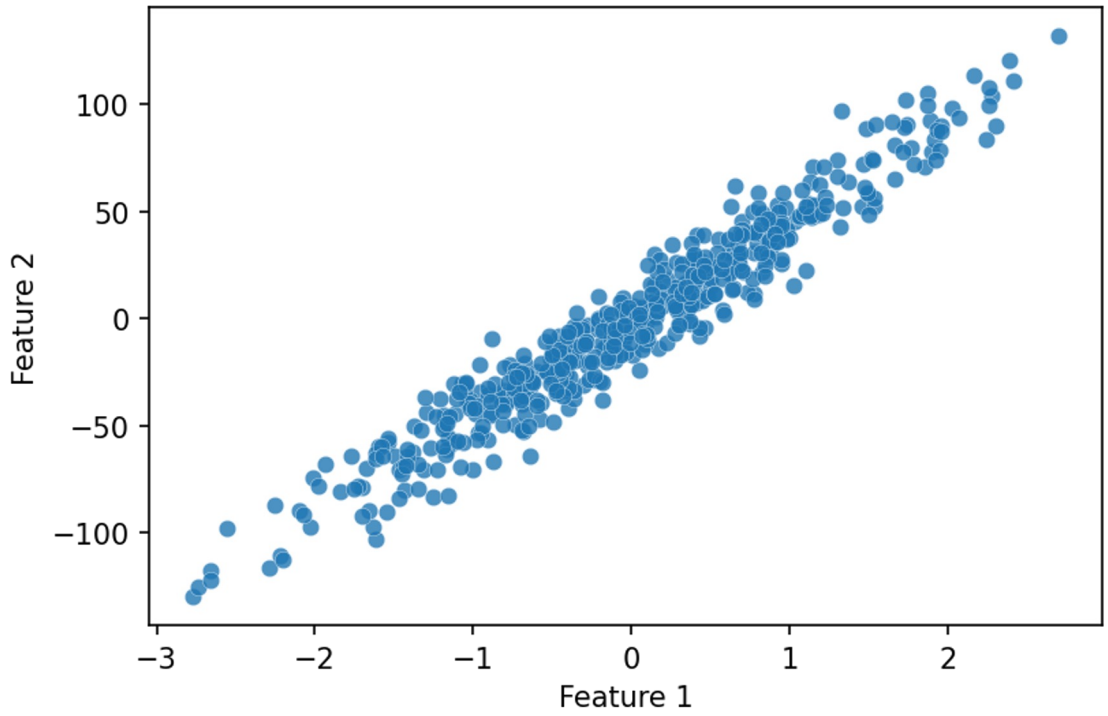

Метод главных компонент

- Объяснение вариативности (Variance Explained)

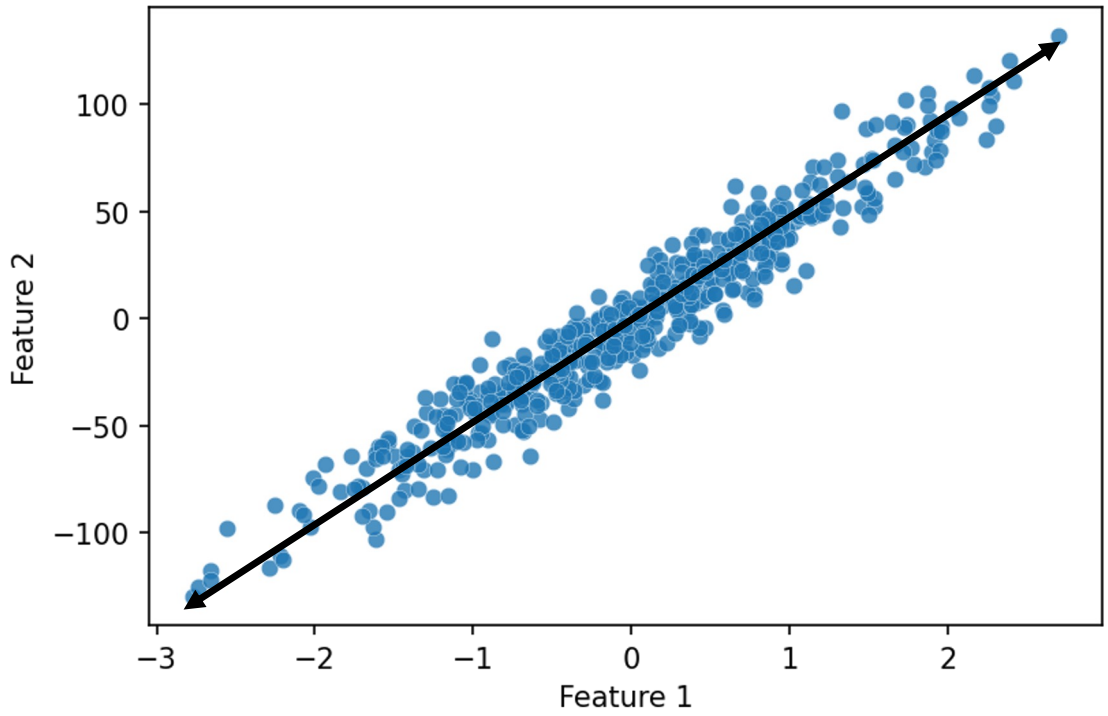

Метод главных компонент

- Объяснение вариативности (Variance Explained)

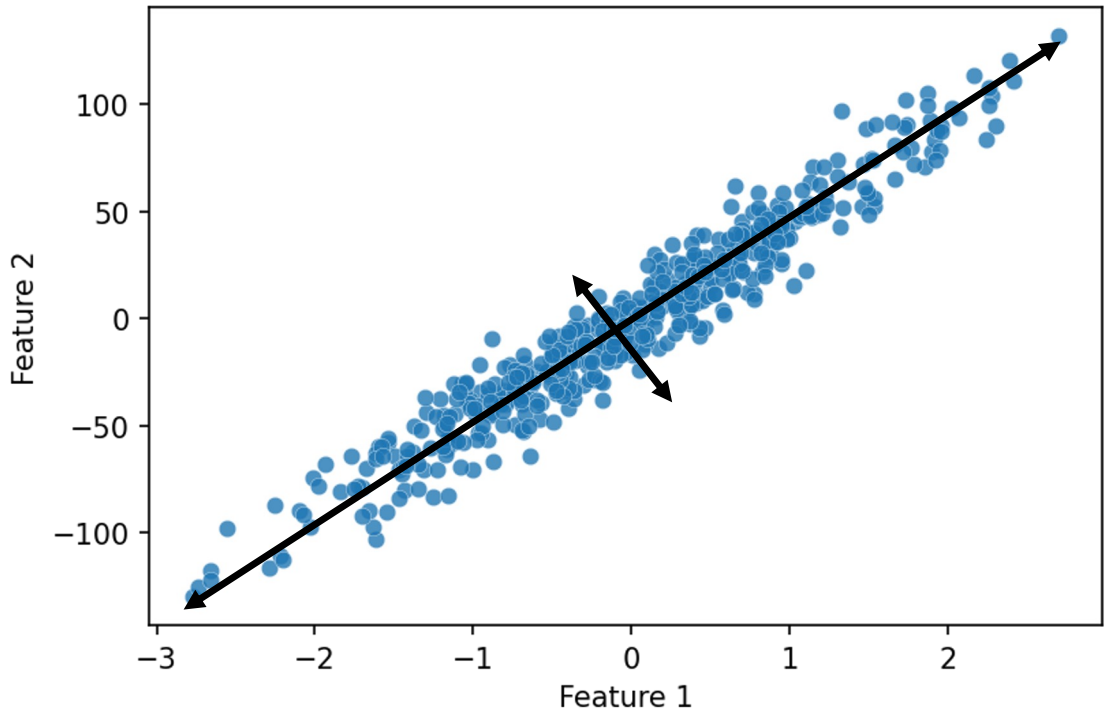

Метод главных компонент

- Объяснение вариативности (Variance Explained)

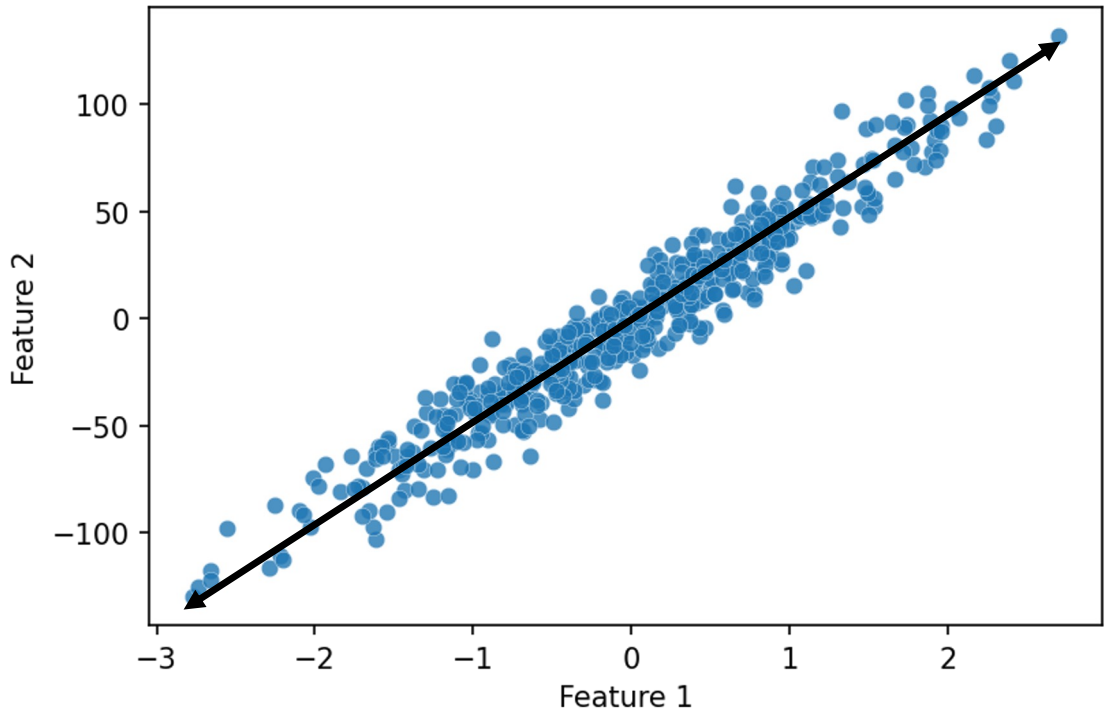

Метод главных компонент

- Объяснение вариативности (Variance Explained)

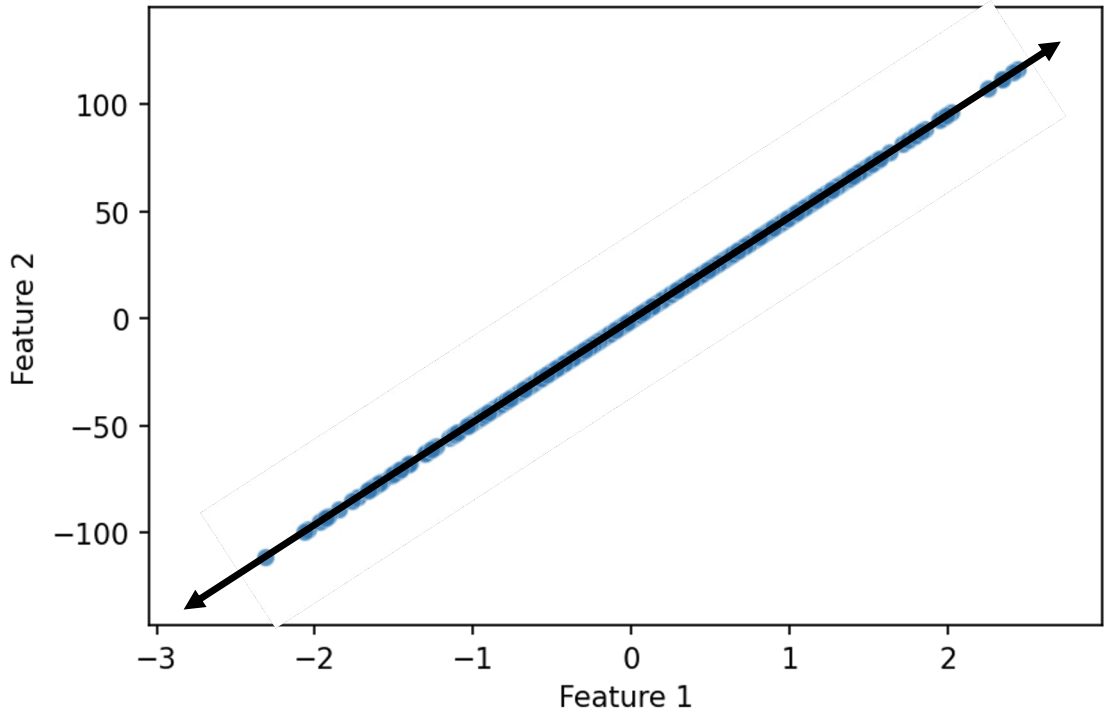

Метод главных компонент

- Объяснение вариативности (Variance Explained)

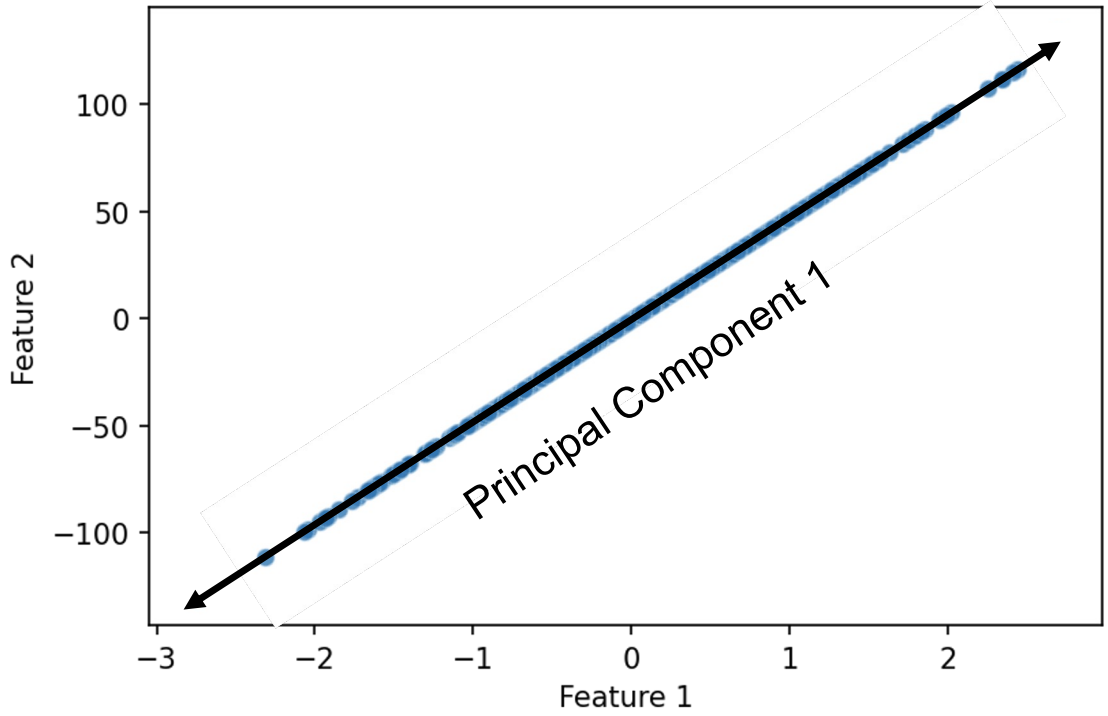

Метод главных компонент

- Объяснение вариативности (Variance Explained)

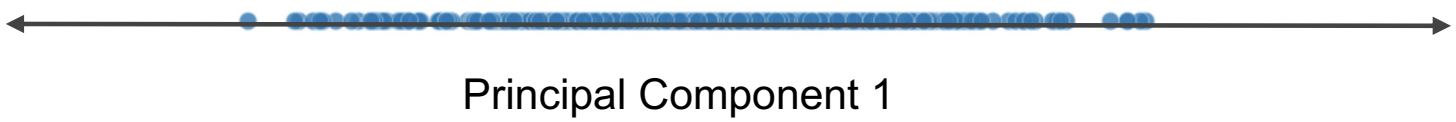

Метод главных компонент

- Объяснение вариативности (Variance Explained)
  - Главная компонента – это линейная комбинация исходных признаков.
  - Чем больше какой-то признак объясняет вариативность в данных, тем больше он участвует в главных компонентах.

Метод главных компонент

- Объяснение вариативности (Variance Explained)
  - Мы перешли от 2 признаков к 1 главной компоненте.
  - Эта 1 главная компонента может “объяснить” некоторый процент вариативности в исходных данных, например 90%.

Метод главных компонент

- Объяснение вариативности (Variance Explained)
  - 100% вариативности объясняются всеми признаками.
  - Баланс между полнотой объяснения вариативности и уменьшением размерности.
  - Можно хорошо сэкономить, если признаков очень много, но из них лишь несколько сильных признаков.

Метод главных компонент

- Далее мы посмотрим на математику метода главных компонент.

Метод главных компонент

Теория – Часть 2

PIERIAN DATA

Метод главных компонент

- Метод главных компонент создаёт новый набор измерений (главных компонент), которые являются линейными комбинациями исходных признаков.

$$Z_1 = \phi_{11}X_1 + \phi_{21}X_2 + \ldots + \phi_{p1}X_p$$

Метод главных компонент

- Метод главных компонент:

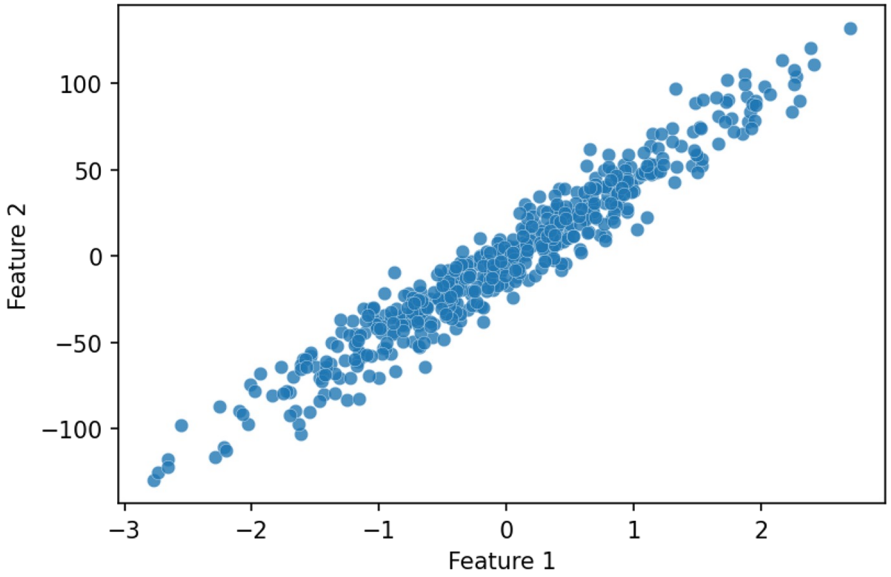

Метод главных компонент

- Метод главных компонент:

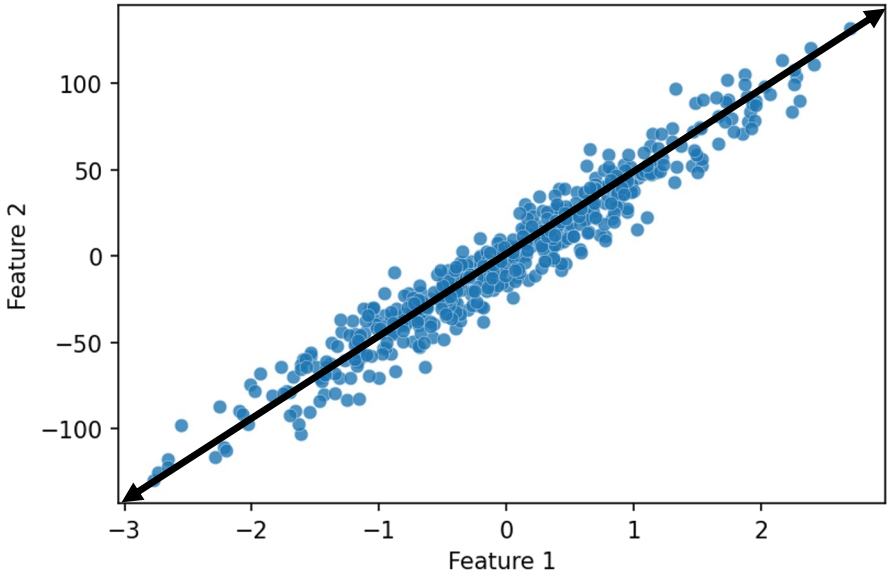

Метод главных компонент

- Метод главных компонент:

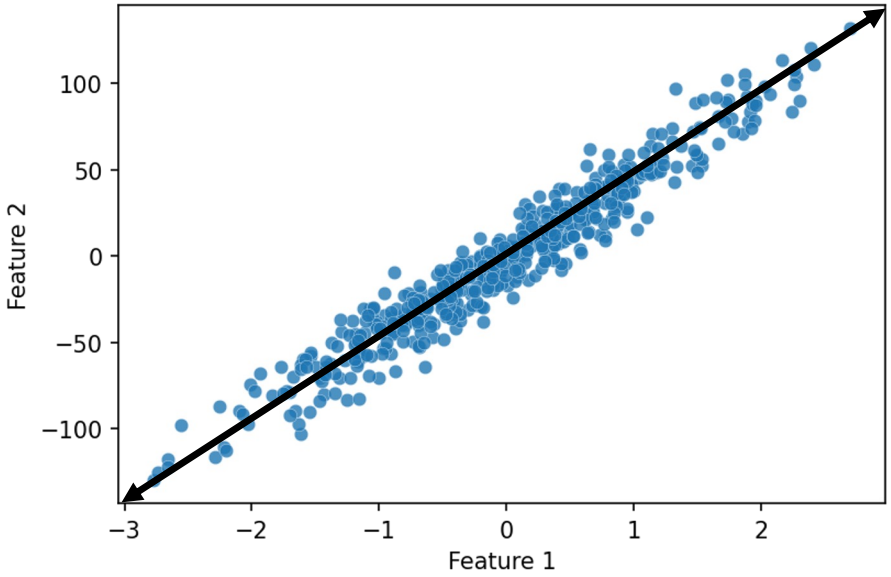

$$Z_1 = \phi_{11} X_1 + \phi_{21} X_2$$

Метод главных компонент

- Метод главных компонент:

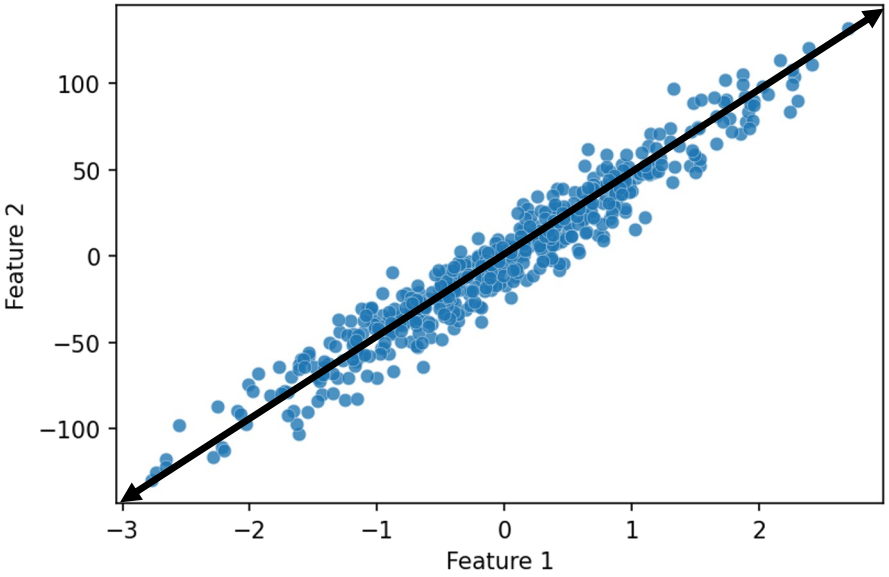

$$Z_1 = \phi_{11} X_1 + \phi_{21} X_2$$

Метод главных компонент

- Метод главных компонент:

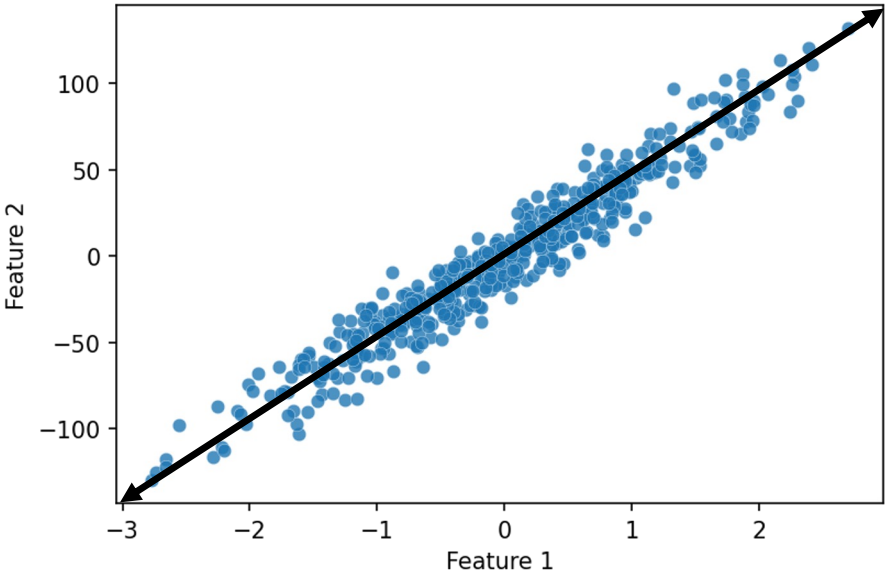

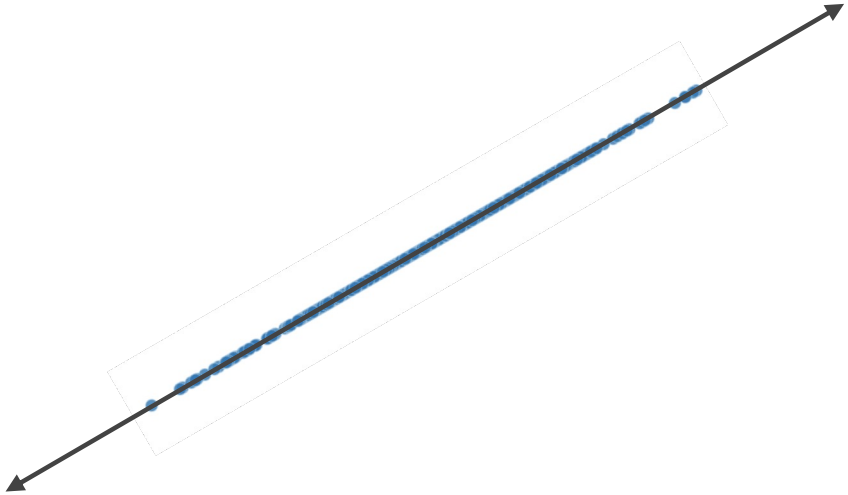

$$Z_1 = \phi_{11} X_1 + \phi_{21} X_2$$

Метод главных компонент

- Метод главных компонент:

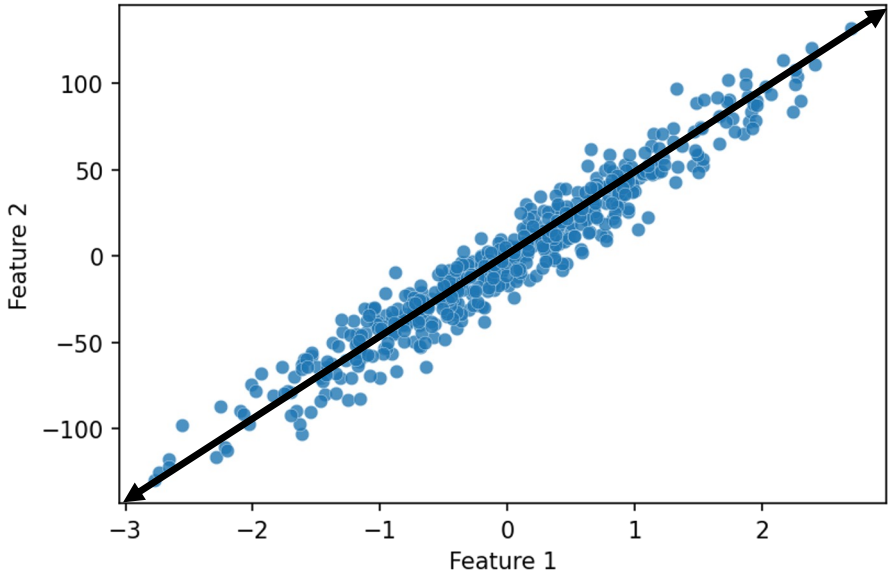

$$Z_1 = \phi_{11} X_1 + \phi_{21} X_2$$

Метод главных компонент

- Метод главных компонент:

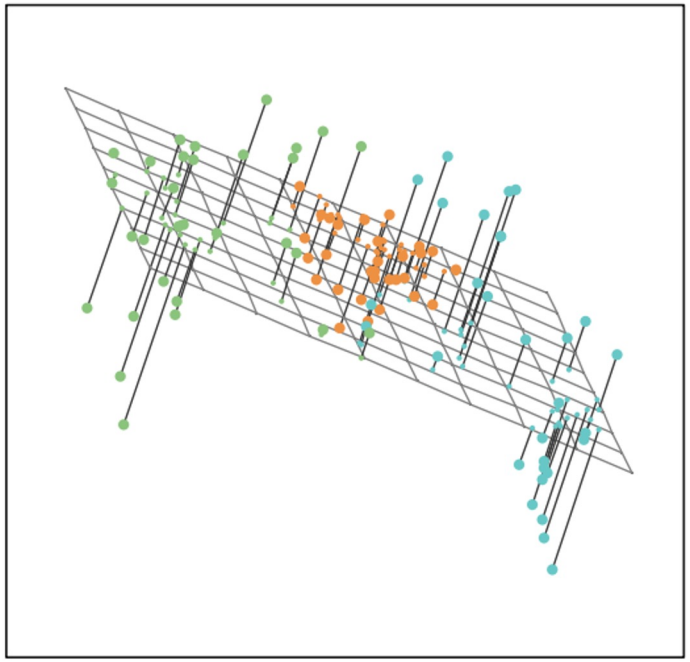

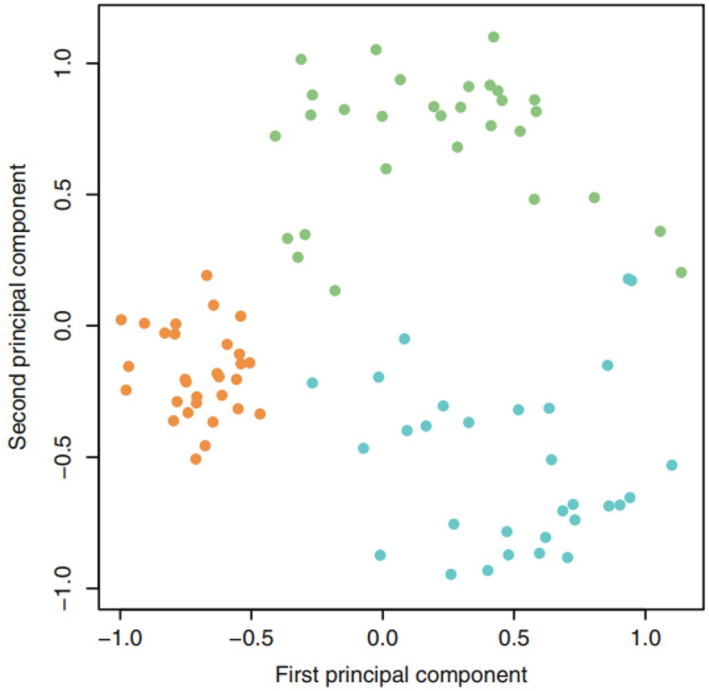

Метод главных компонент

- Как мы можем вычислить эти компоненты?
- Давайте пройдём нужные шаги и посмотрим их визуально.

Метод главных компонент

- Начнём с 2 измерений:

X1	X2
1	2
2	1
3	2
4	4
5	3
6	5

Метод главных компонент

- Начнём с 2 измерений:

X1	X2
1	2
2	1
3	2
4	4
5	3
6	5

Метод главных компонент

- Начнём с 2 измерений:

X1	X2
1	2
2	1
3	2
4	4
5	3
6	5

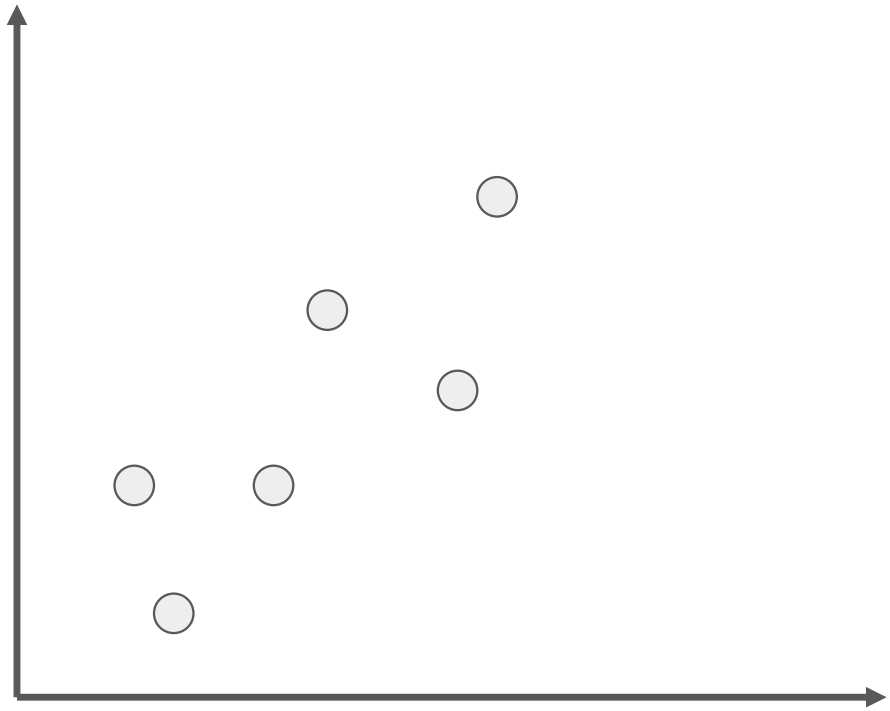

Метод главных компонент

- Далее стандартизуем данные:

X1	X2
1	2
2	1
3	2
4	4
5	3
6	5

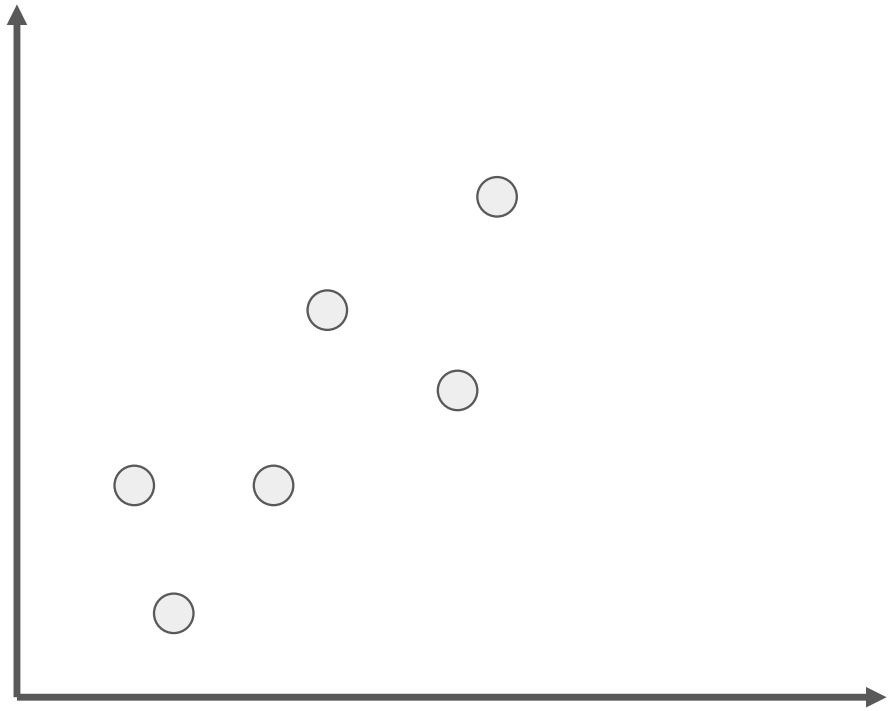

Метод главных компонент

- Далее стандартизуем данные:

X1	X2
1	2
2	1
3	2
4	4
5	3
6	5

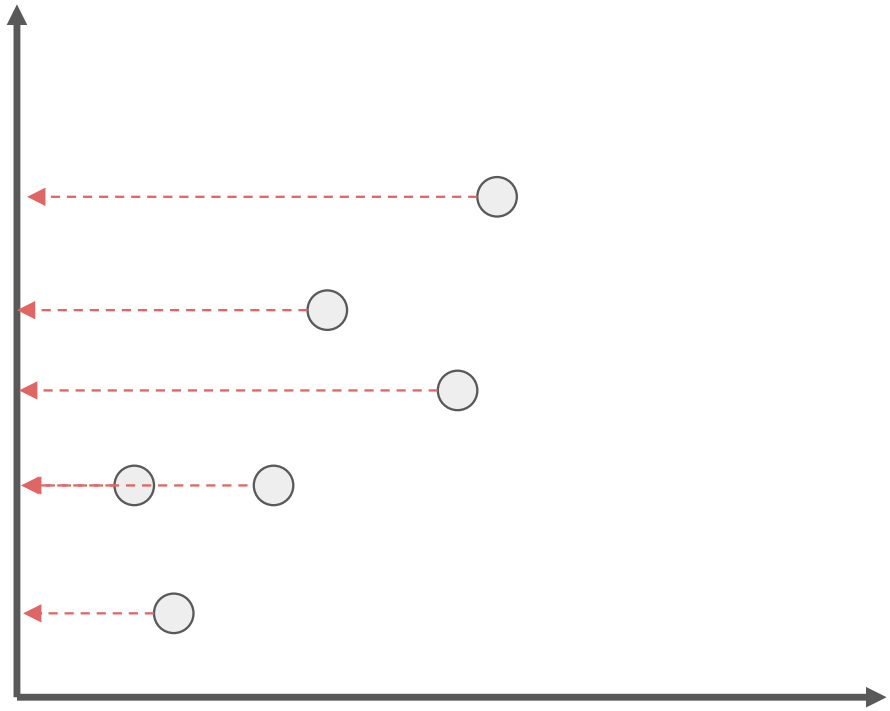

Метод главных компонент

- Далее стандартизуем данные:

X1	X2
1	2
2	1
3	2
4	4
5	3
6	5

Метод главных компонент

- Далее стандартизуем данные:

X1	X2
1	2
2	1
3	2
4	4
5	3
6	5

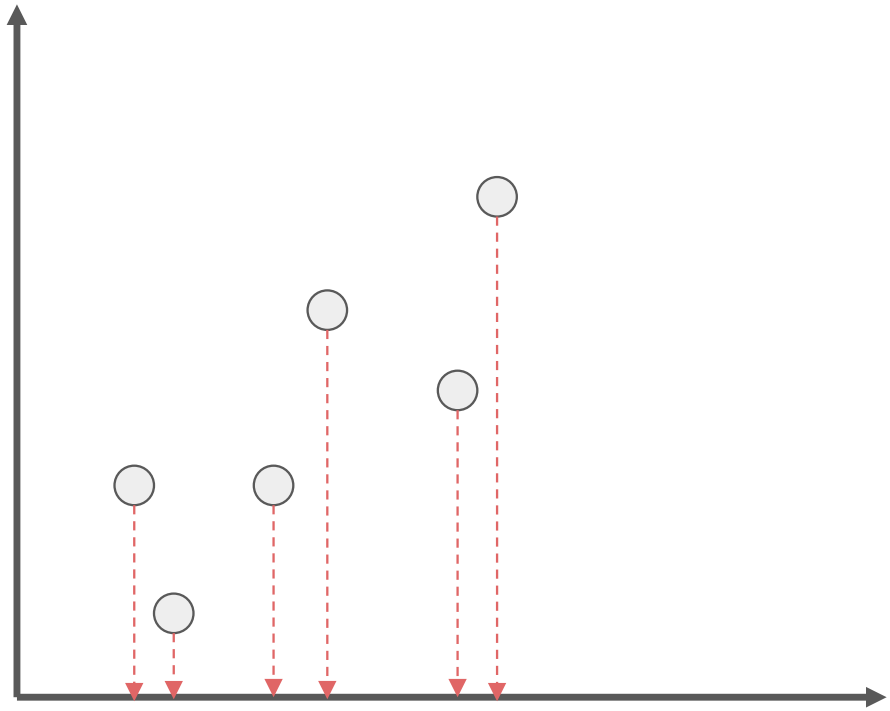

Метод главных компонент

- Далее стандартизуем данные:

X1	X2
1	2
2	1
3	2
4	4
5	3
6	5

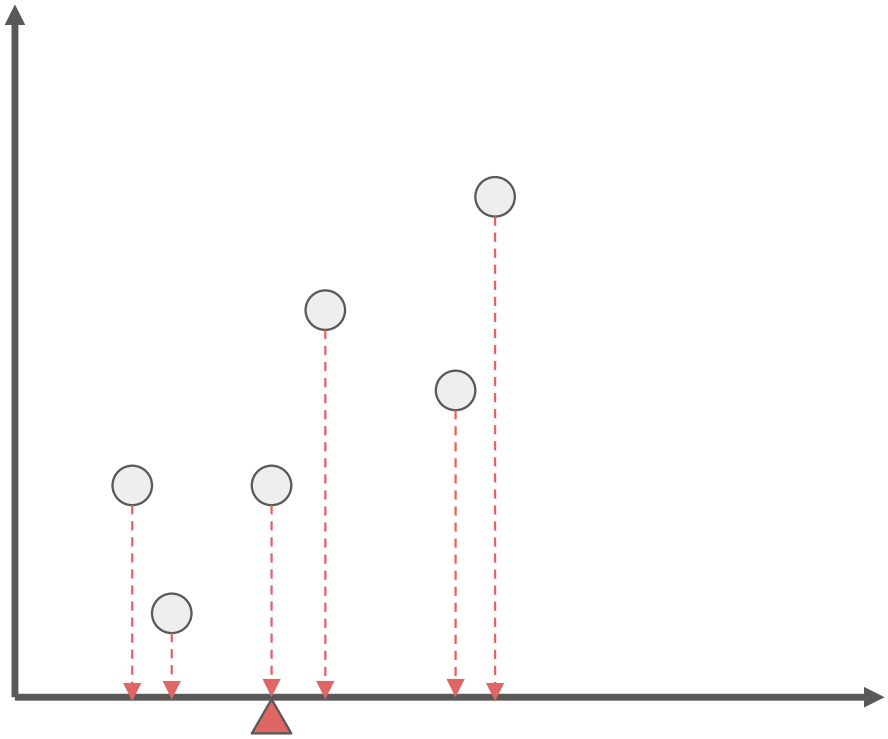

Метод главных компонент

- Далее стандартизуем данные:

X1	X2
1	2
2	1
3	2
4	4
5	3
6	5

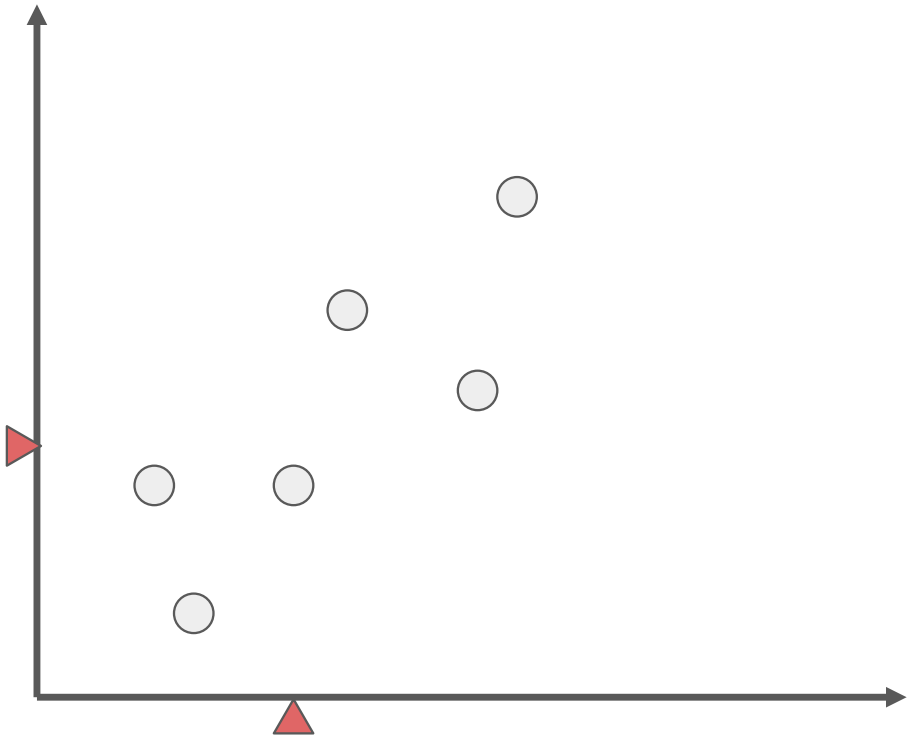

Метод главных компонент

- Далее стандартизуем данные:

X1	X2
1	2
2	1
3	2
4	4
5	3
6	5

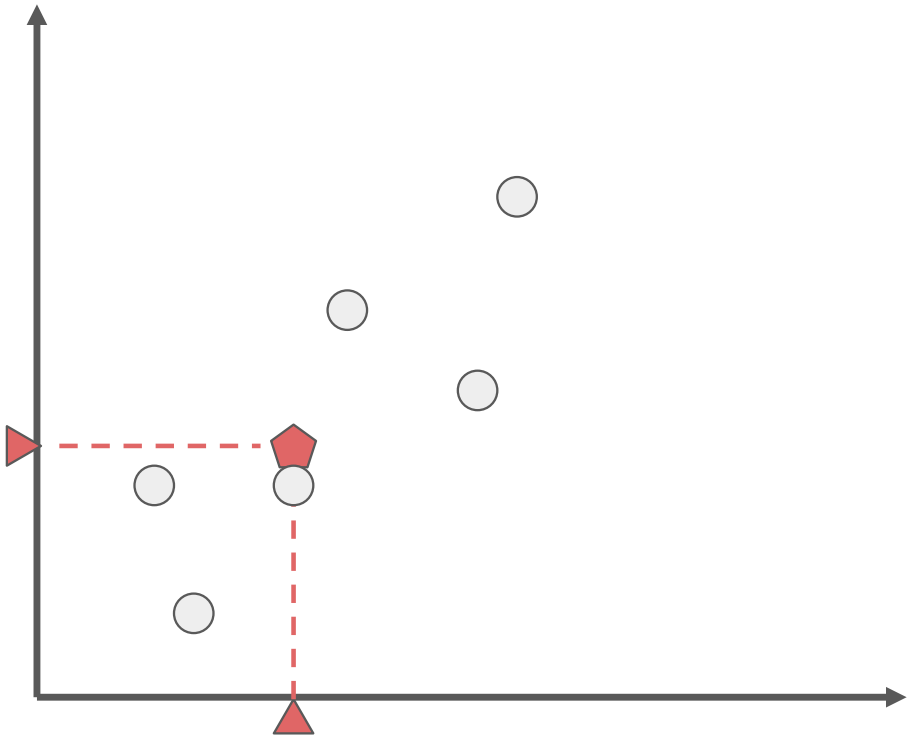

Метод главных компонент

- Далее стандартизуем данные:

X1	X2
1	2
2	1
3	2
4	4
5	3
6	5

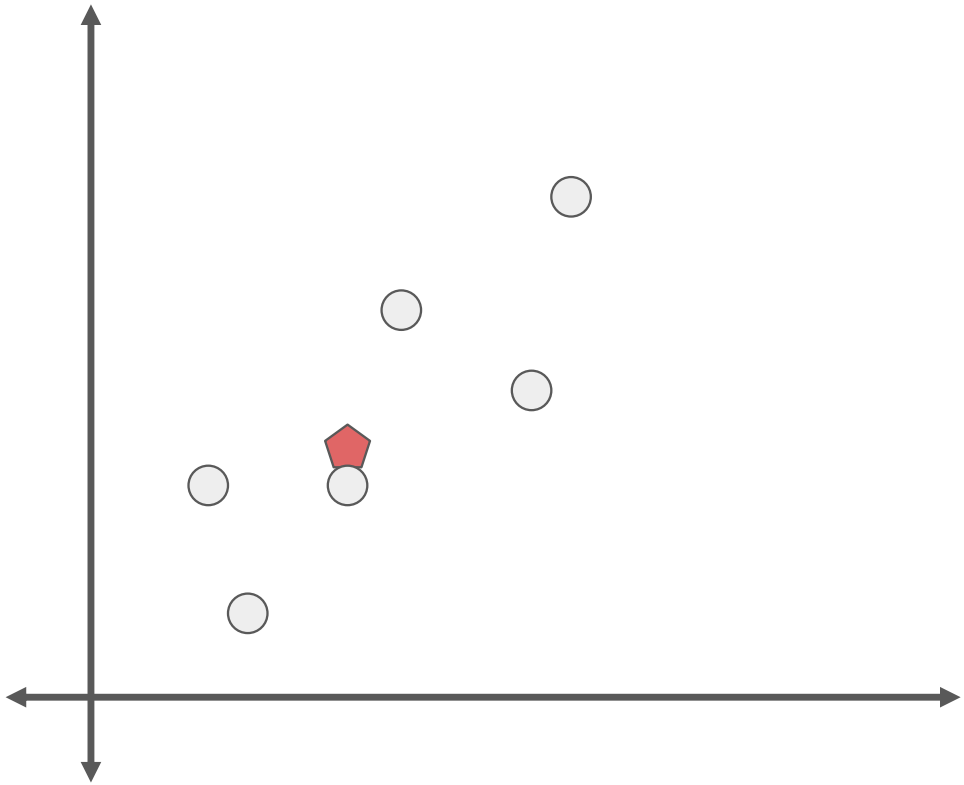

Метод главных компонент

- Далее стандартизуем данные:

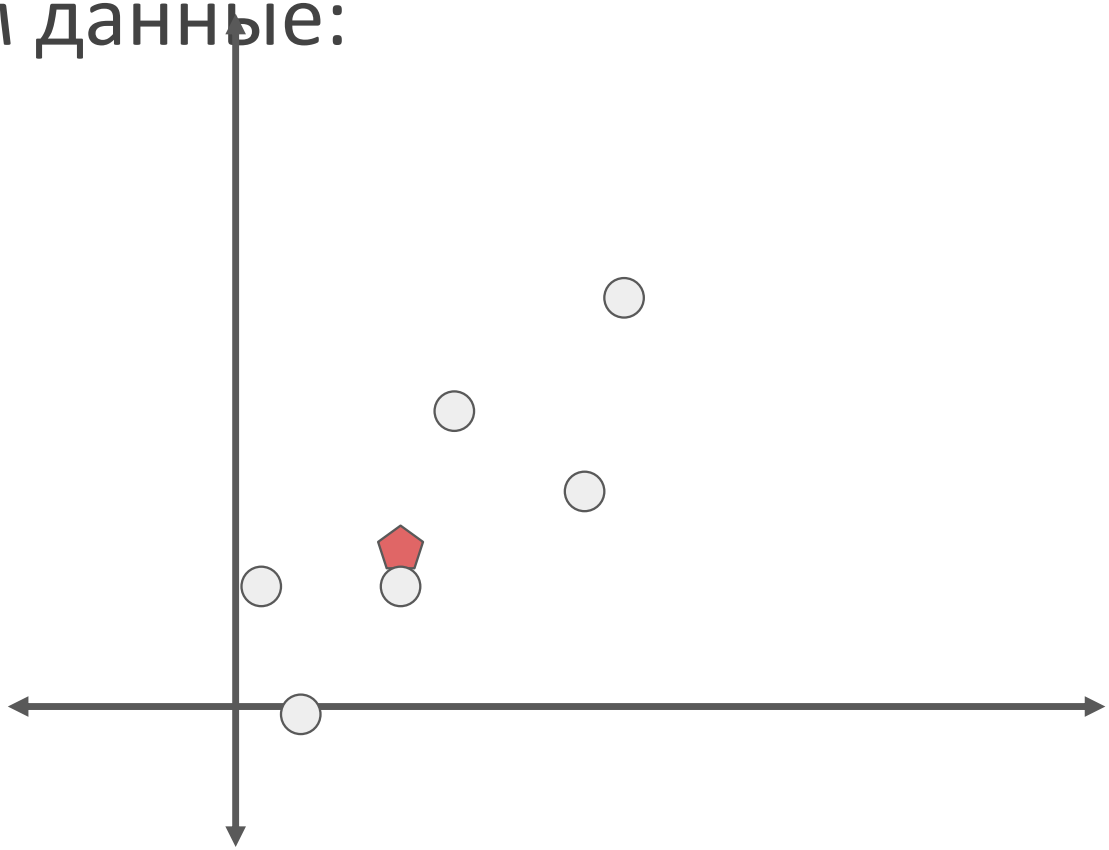

Метод главных компонент

- Далее стандартизуем данные:

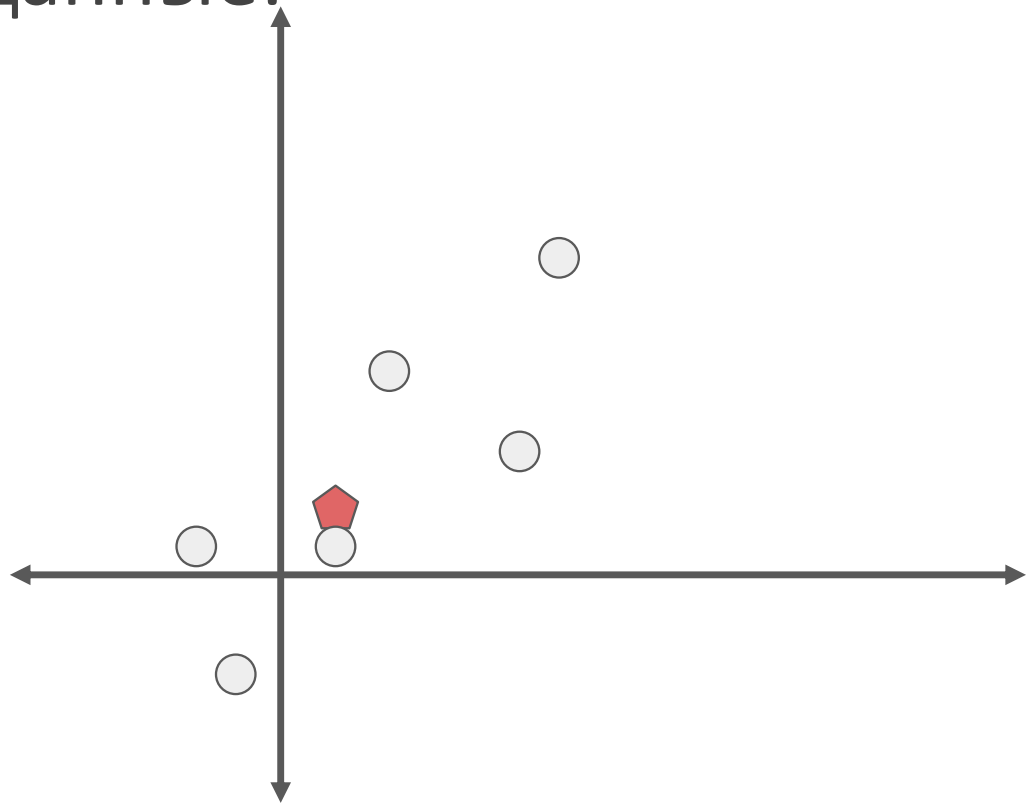

Метод главных компонент

- Далее стандартизуем данные:

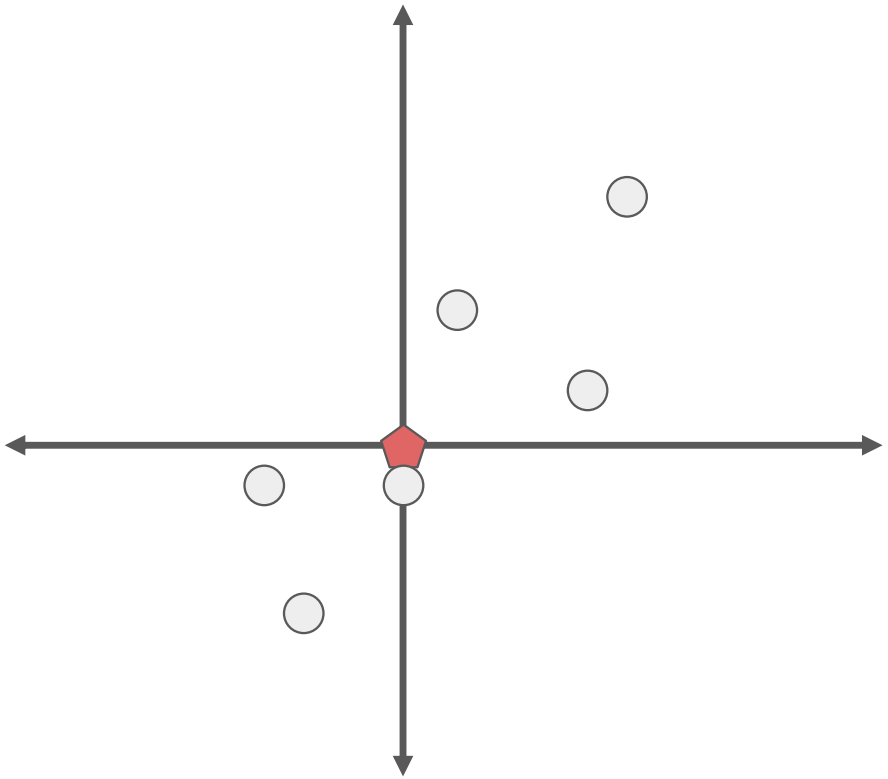

Метод главных компонент

- Вычисляем ковариационную матрицу для данных:

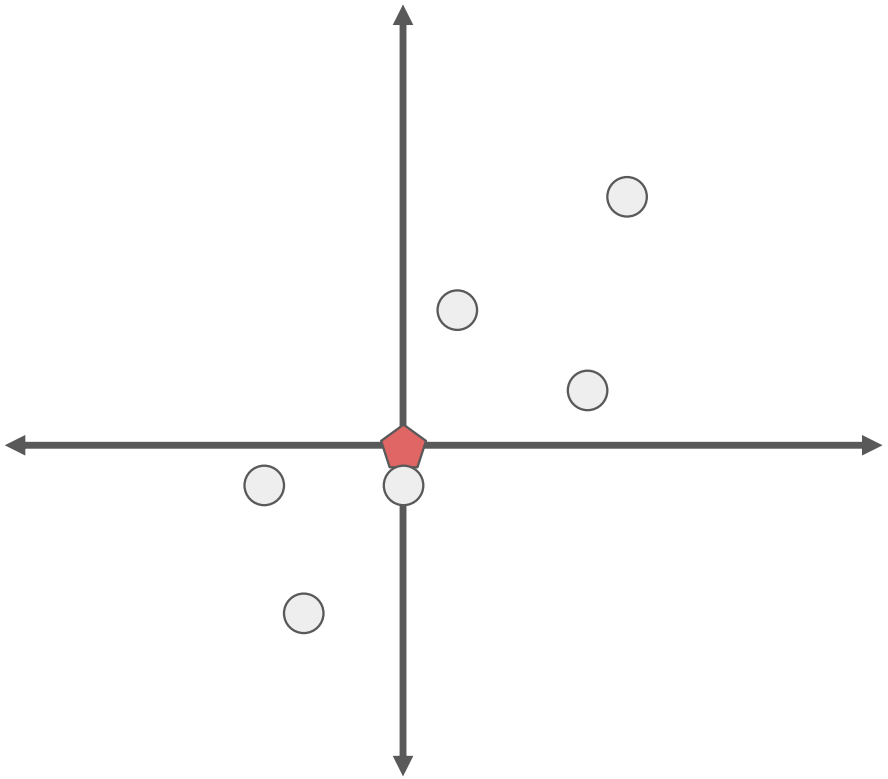

Метод главных компонент

- Линейное преобразование данных:

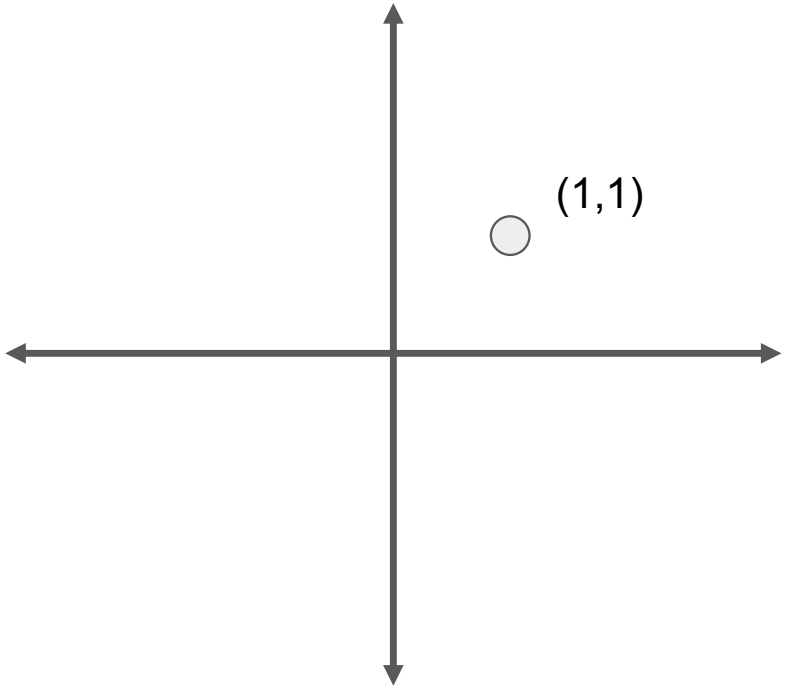

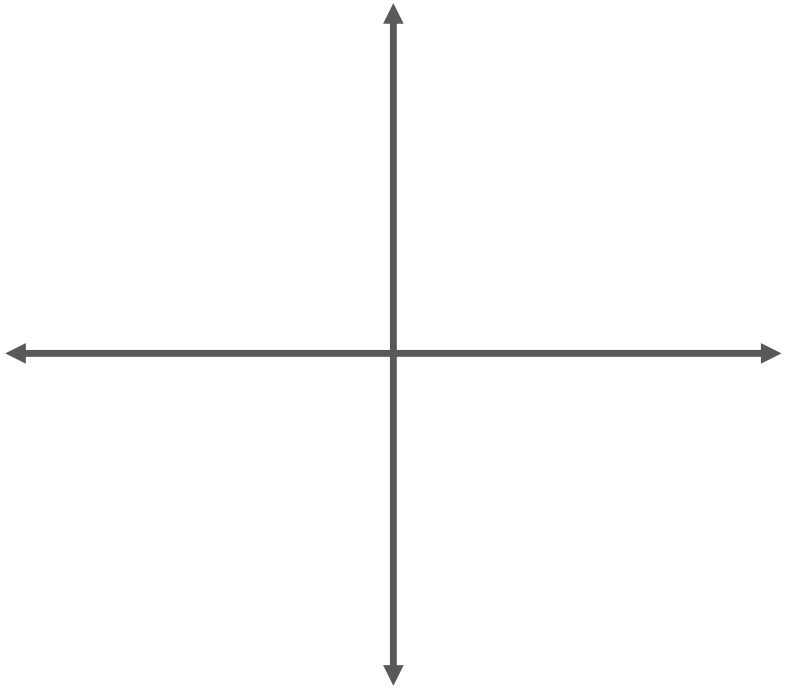

Метод главных компонент

- Линейное преобразование данных:

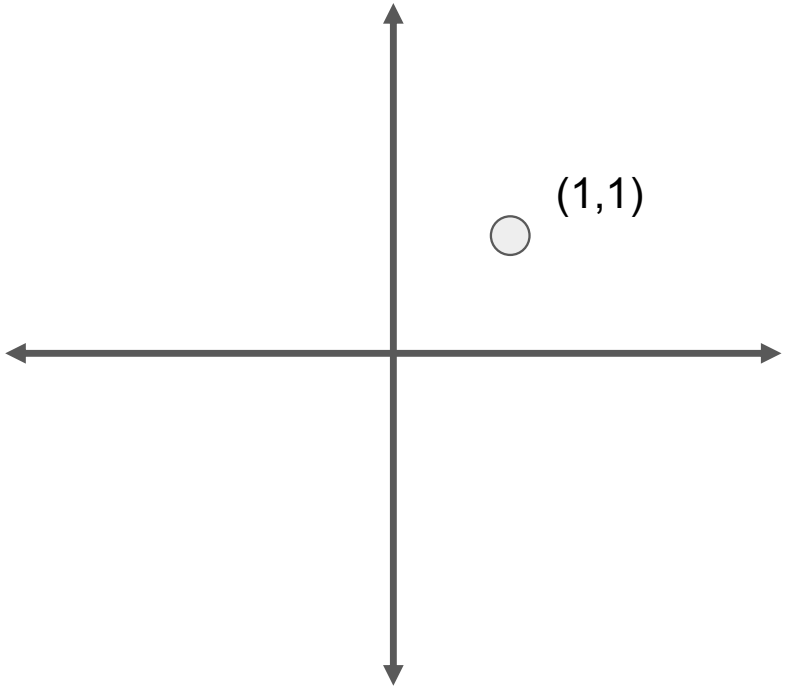

$$\begin{bmatrix} a1 & b1 \\ a2 & b2 \end{bmatrix}$$

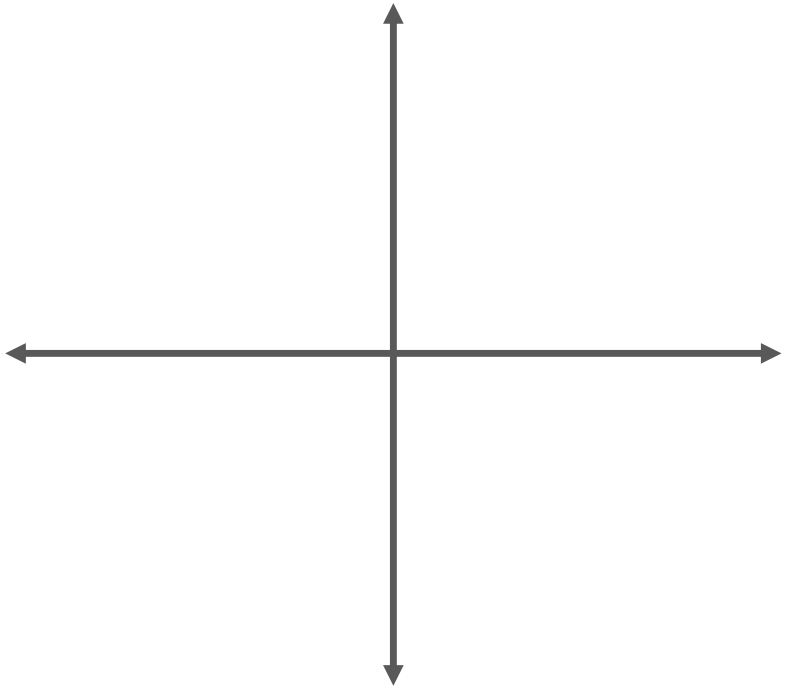

Метод главных компонент

- Линейное преобразование данных:

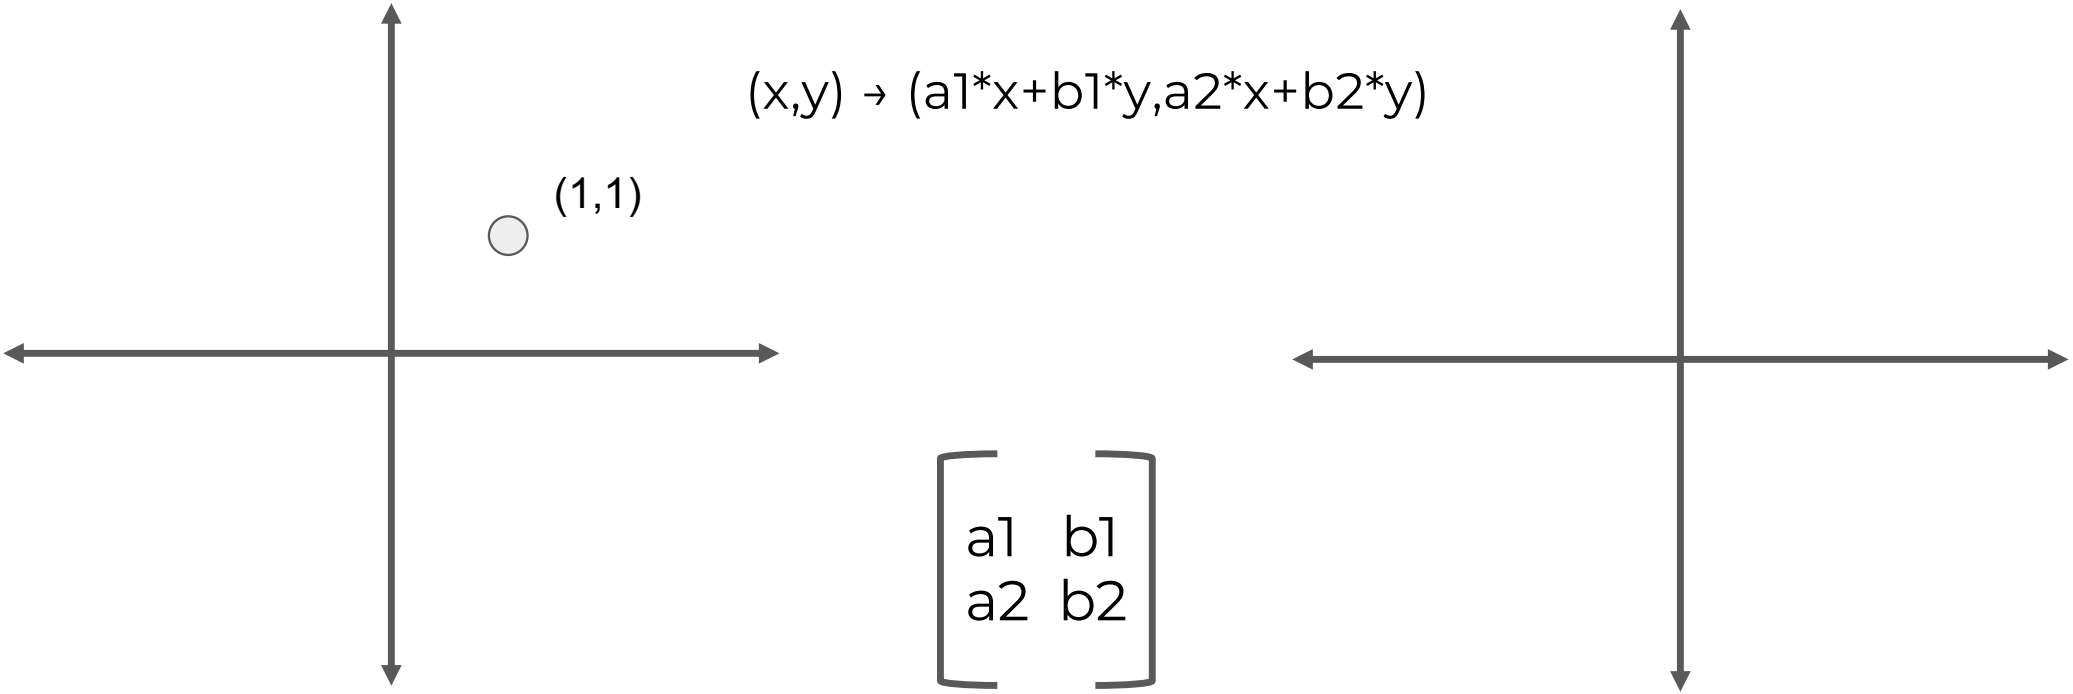

Метод главных компонент

- Линейное преобразование данных:

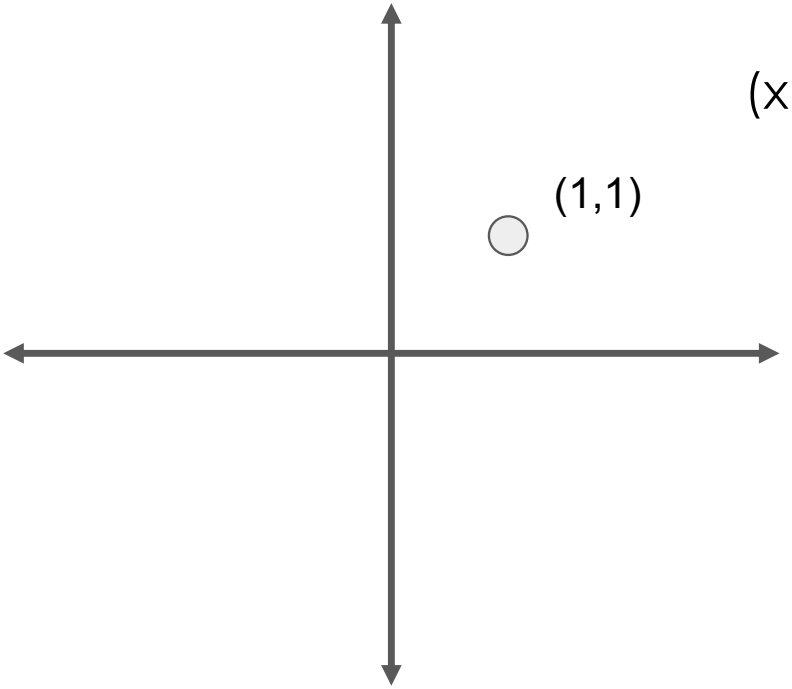

(x,y) → (a1*x+b1*y,a2*x+b2*y)

$$\begin{bmatrix} a1 & b1 \\ a2 & b2 \end{bmatrix}$$

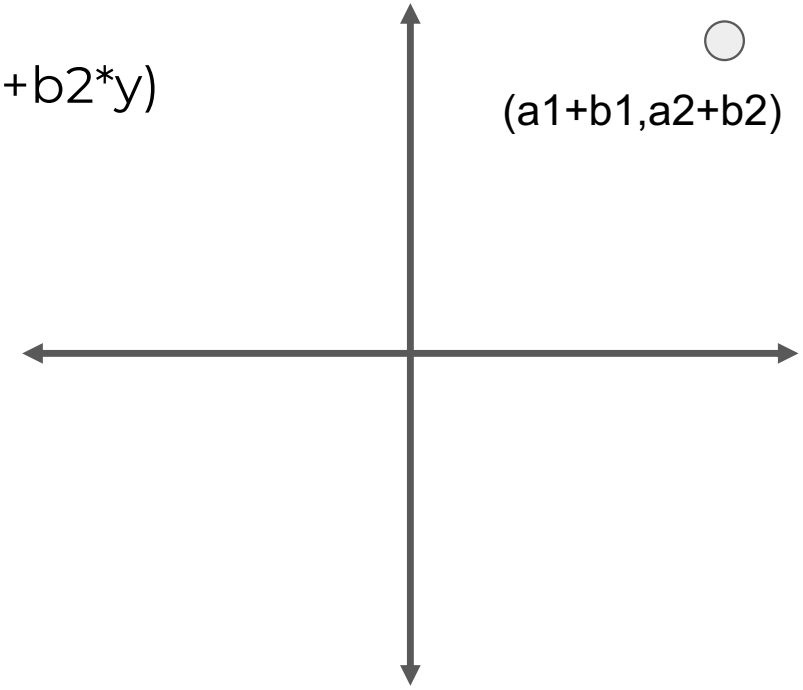

Метод главных компонент

- Линейное преобразование данных:

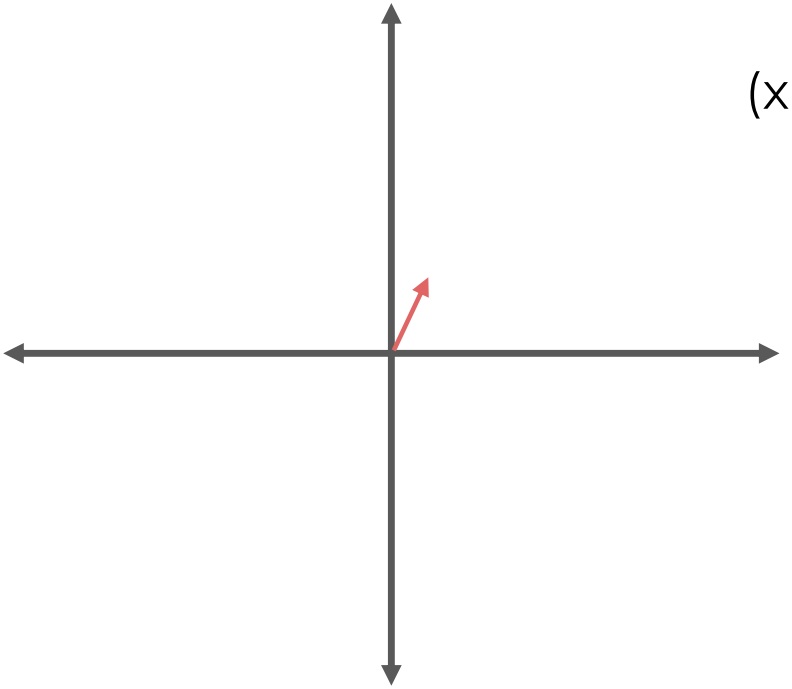

$$(x,y) \rightarrow (a1*x+b1*y, a2*x+b2*y)$$

$$\begin{bmatrix} a1 & b1 \\ a2 & b2 \end{bmatrix}$$

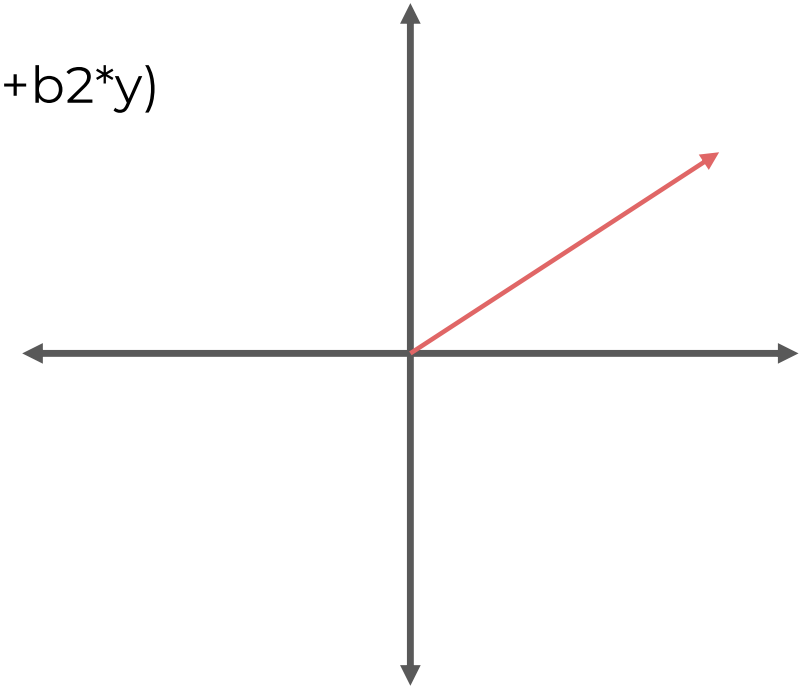

Метод главных компонент

- Линейное преобразование данных:

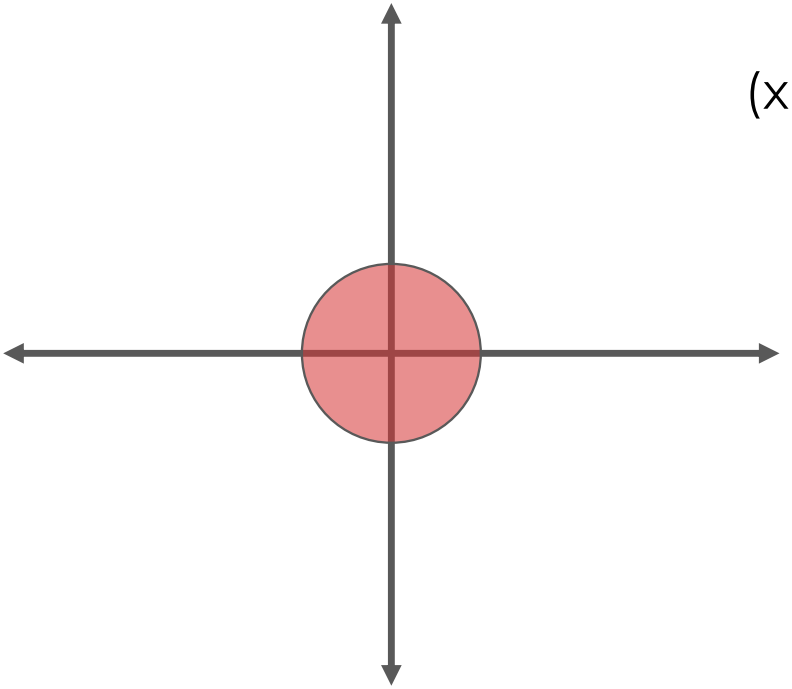

$$(x,y) \rightarrow (a1*x+b1*y, a2*x+b2*y)$$

$$\begin{bmatrix} a1 & b1 \\ a2 & b2 \end{bmatrix}$$

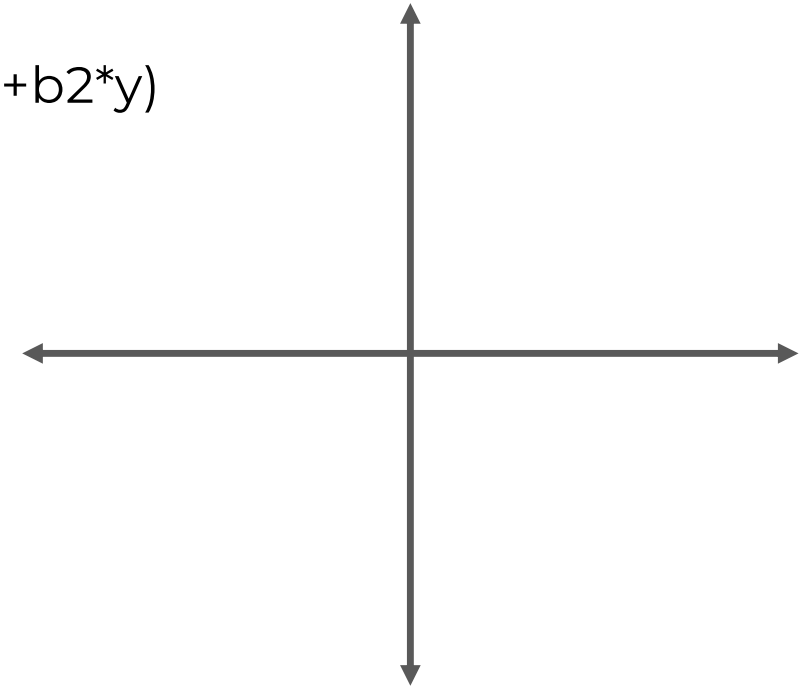

Метод главных компонент

- Линейное преобразование данных:

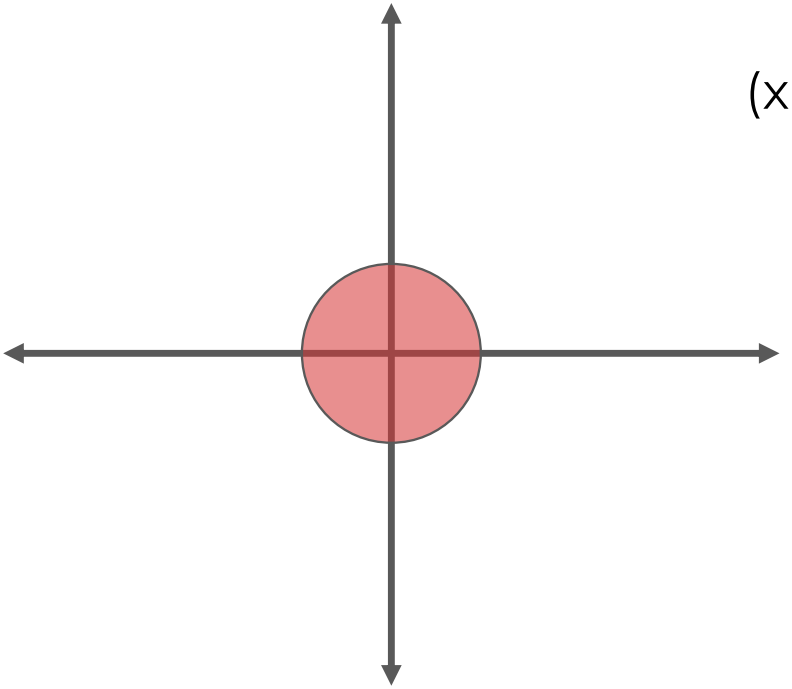

$$(x,y) \rightarrow (a1*x+b1*y, a2*x+b2*y)$$

$$\begin{bmatrix} a1 & b1 \\ a2 & b2 \end{bmatrix}$$

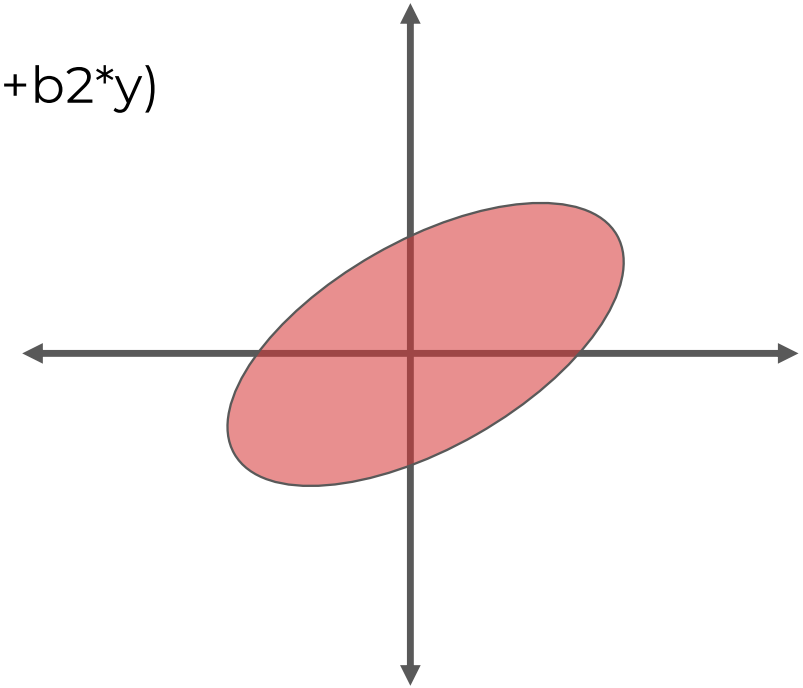

Метод главных компонент

- Линейное преобразование данных:

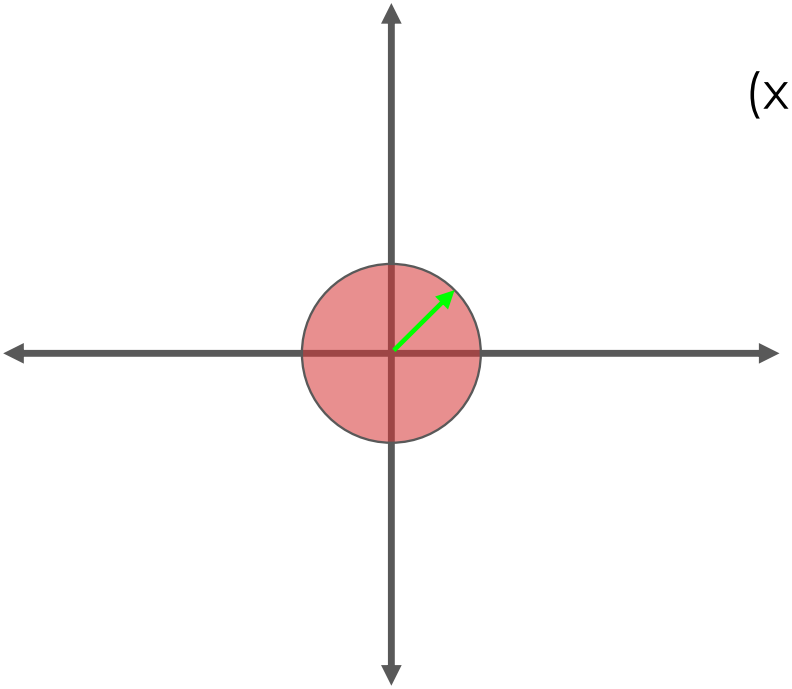

$$(x,y) \rightarrow (a1*x+b1*y, a2*x+b2*y)$$

$$\begin{bmatrix} a1 & b1 \\ a2 & b2 \end{bmatrix}$$

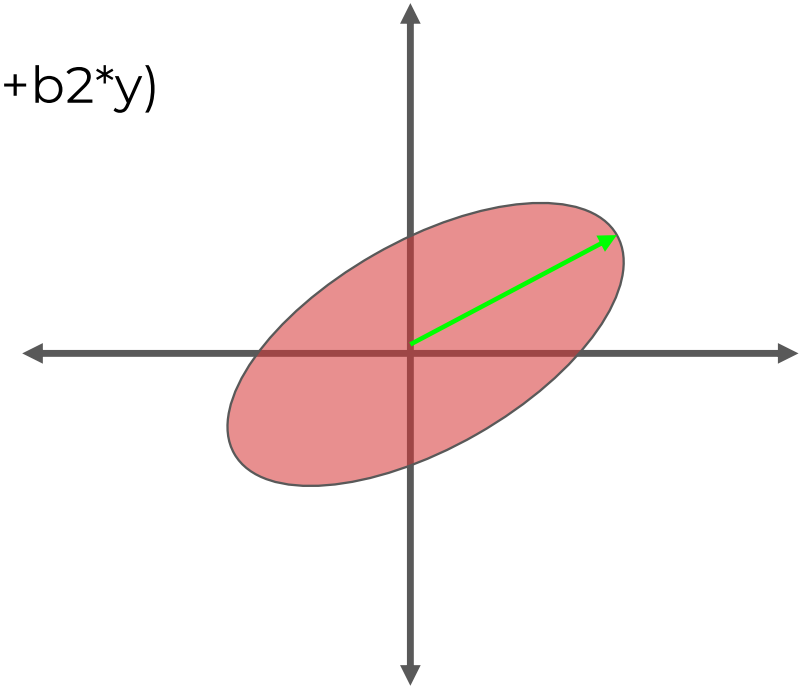

Метод главных компонент

- Собственный вектор (EigenVector) - направление

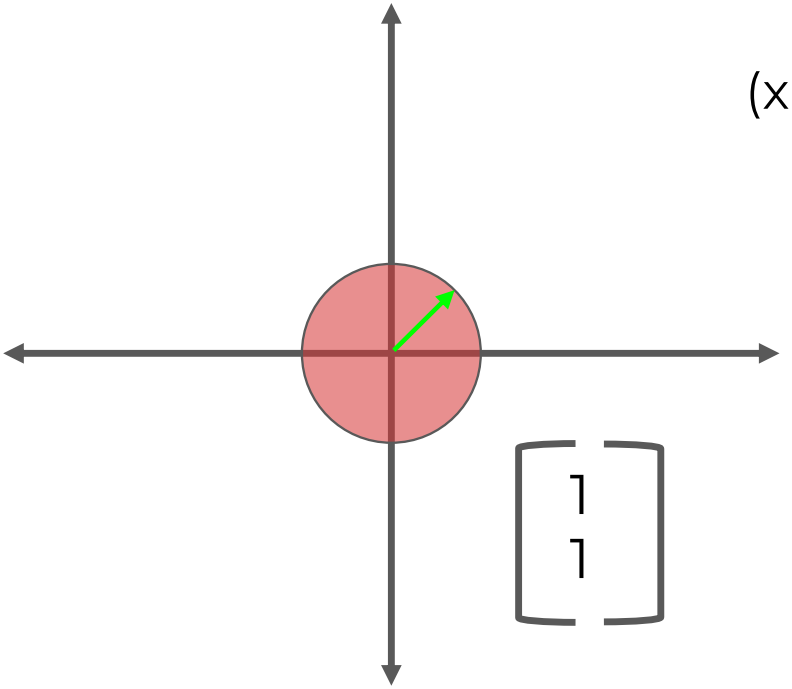

(x,y) → (a1*x+b1*y,a2*x+b2*y)

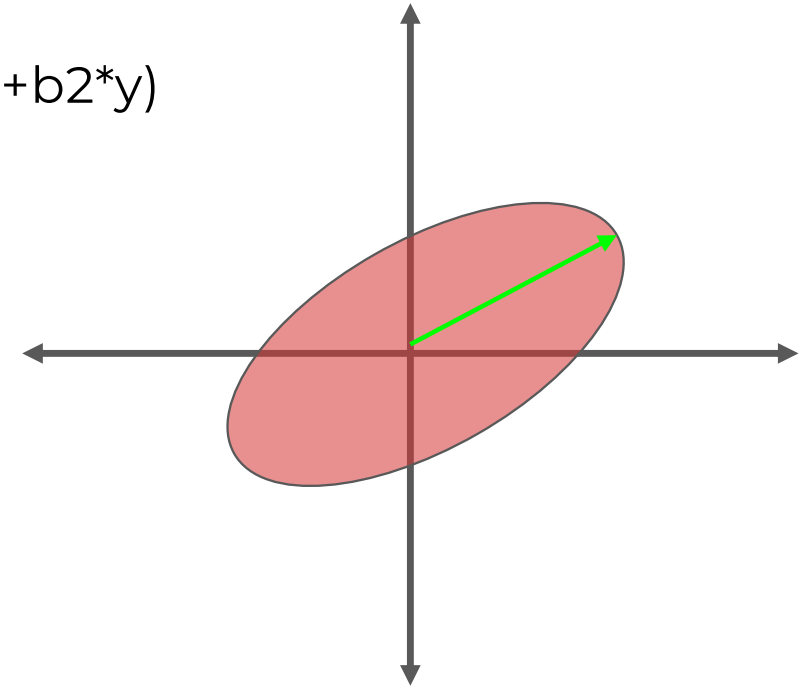

Метод главных компонент

- Собственный вектор (EigenVector) - направление

(x,y) → (a1*x+b1*y,a2*x+b2*y)

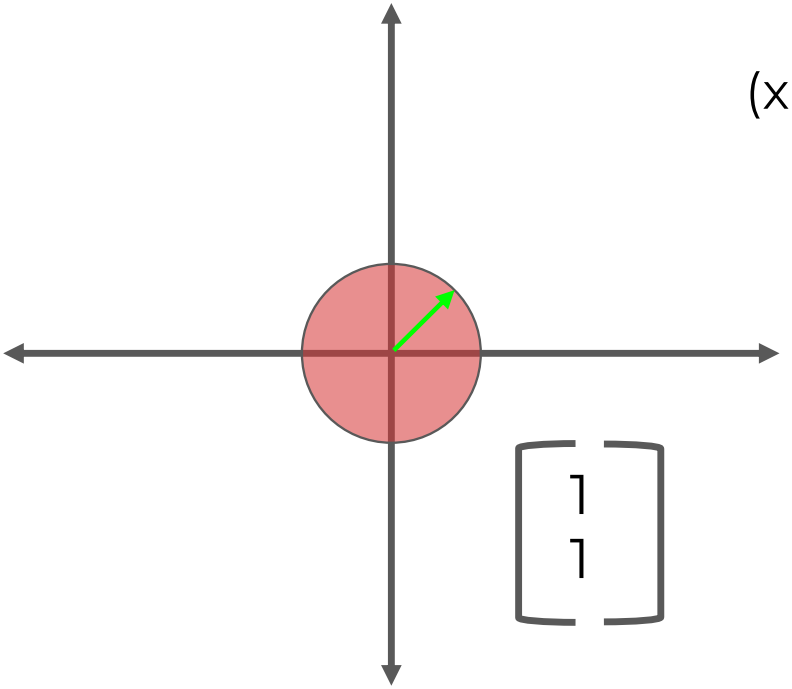

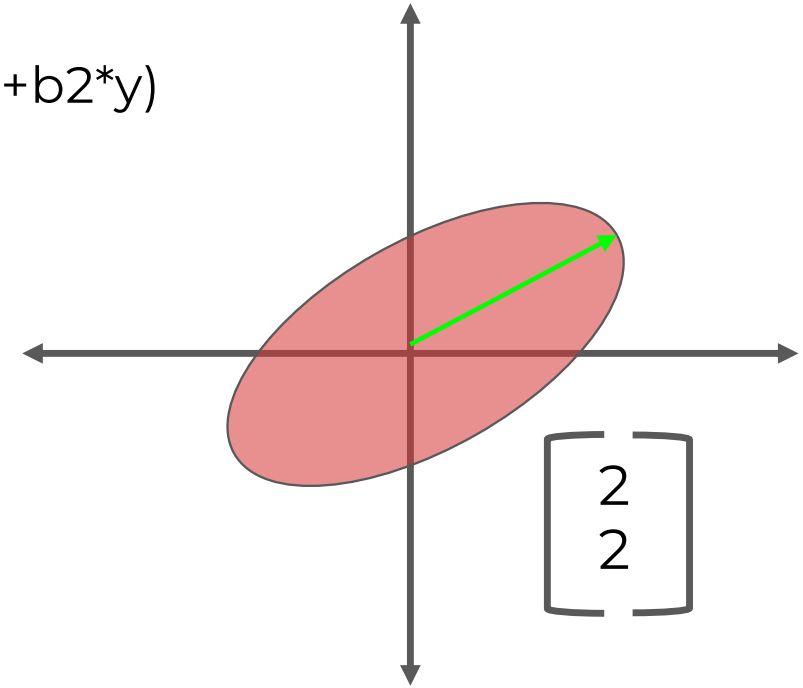

Метод главных компонент

- Собственное значение (EigenValue) - величина

(x,y) → (a1*x+b1*y,a2*x+b2*y)

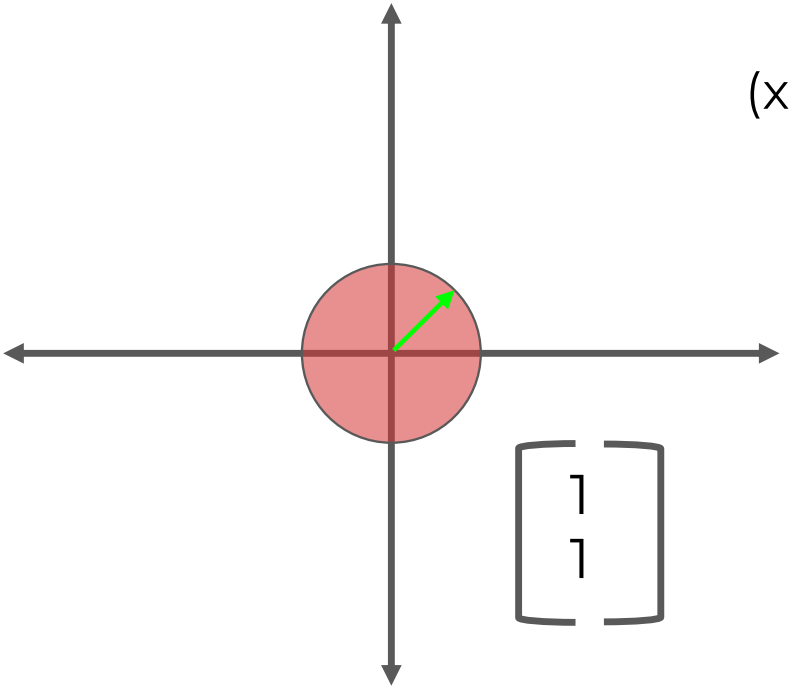

$$\begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\begin{bmatrix} a1 & b1 \\ a2 & b2 \end{bmatrix}$$

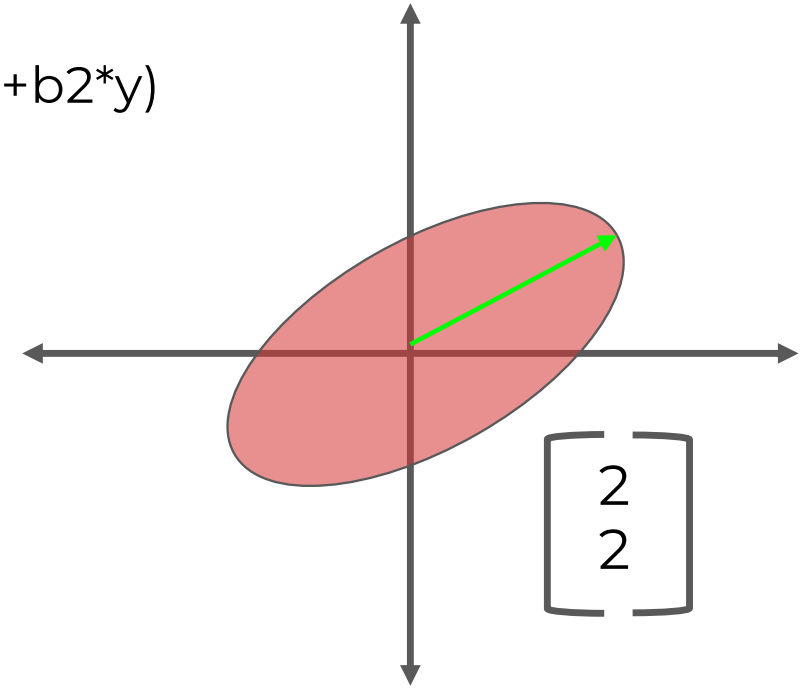

$$\begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

Метод главных компонент

- Собственное значение (EigenValue) - величина

$$(x,y) \rightarrow (a1*x+b1*y, a2*x+b2*y)$$

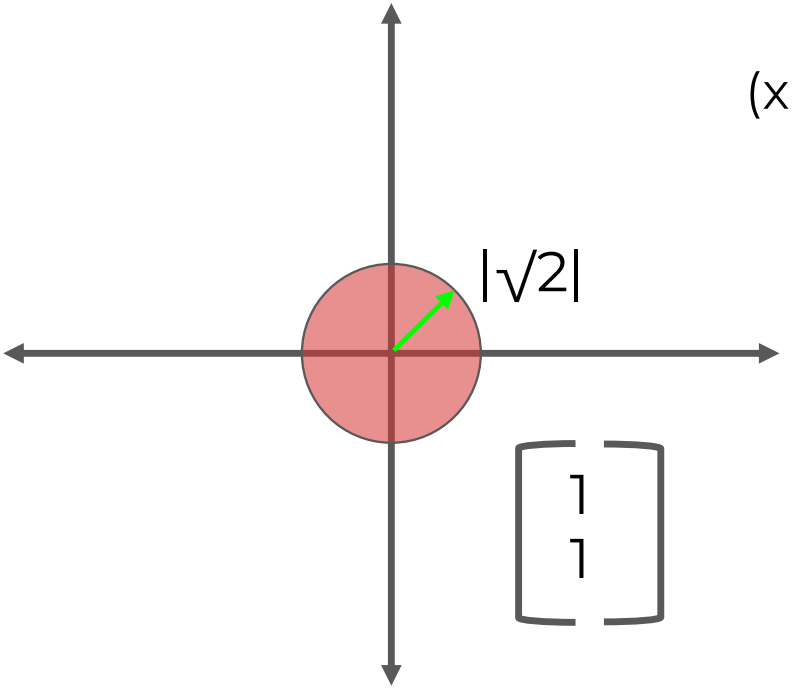

$$\begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\begin{bmatrix} a1 & b1 \\ a2 & b2 \end{bmatrix}$$

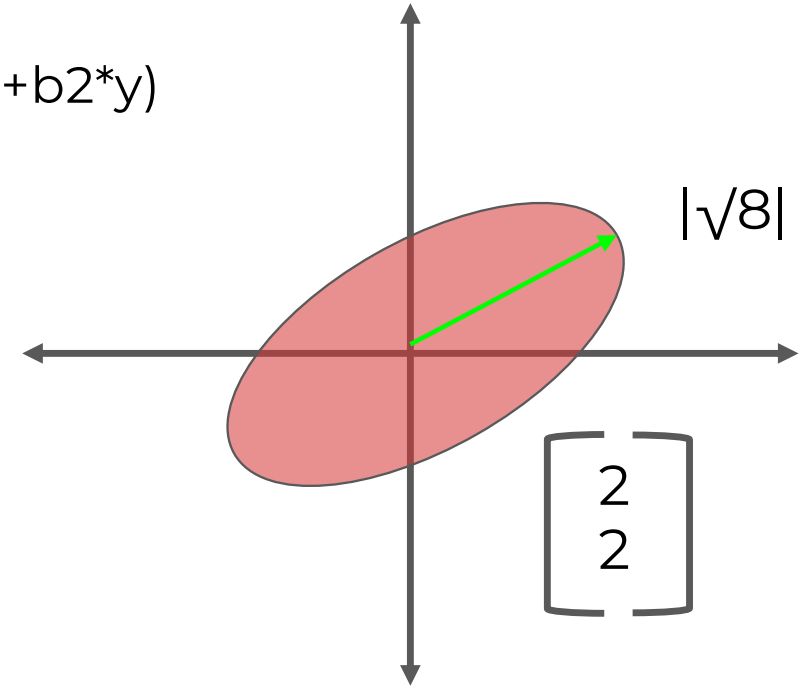

$$\begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

Метод главных компонент

- Перпендикулярный собственный вектор

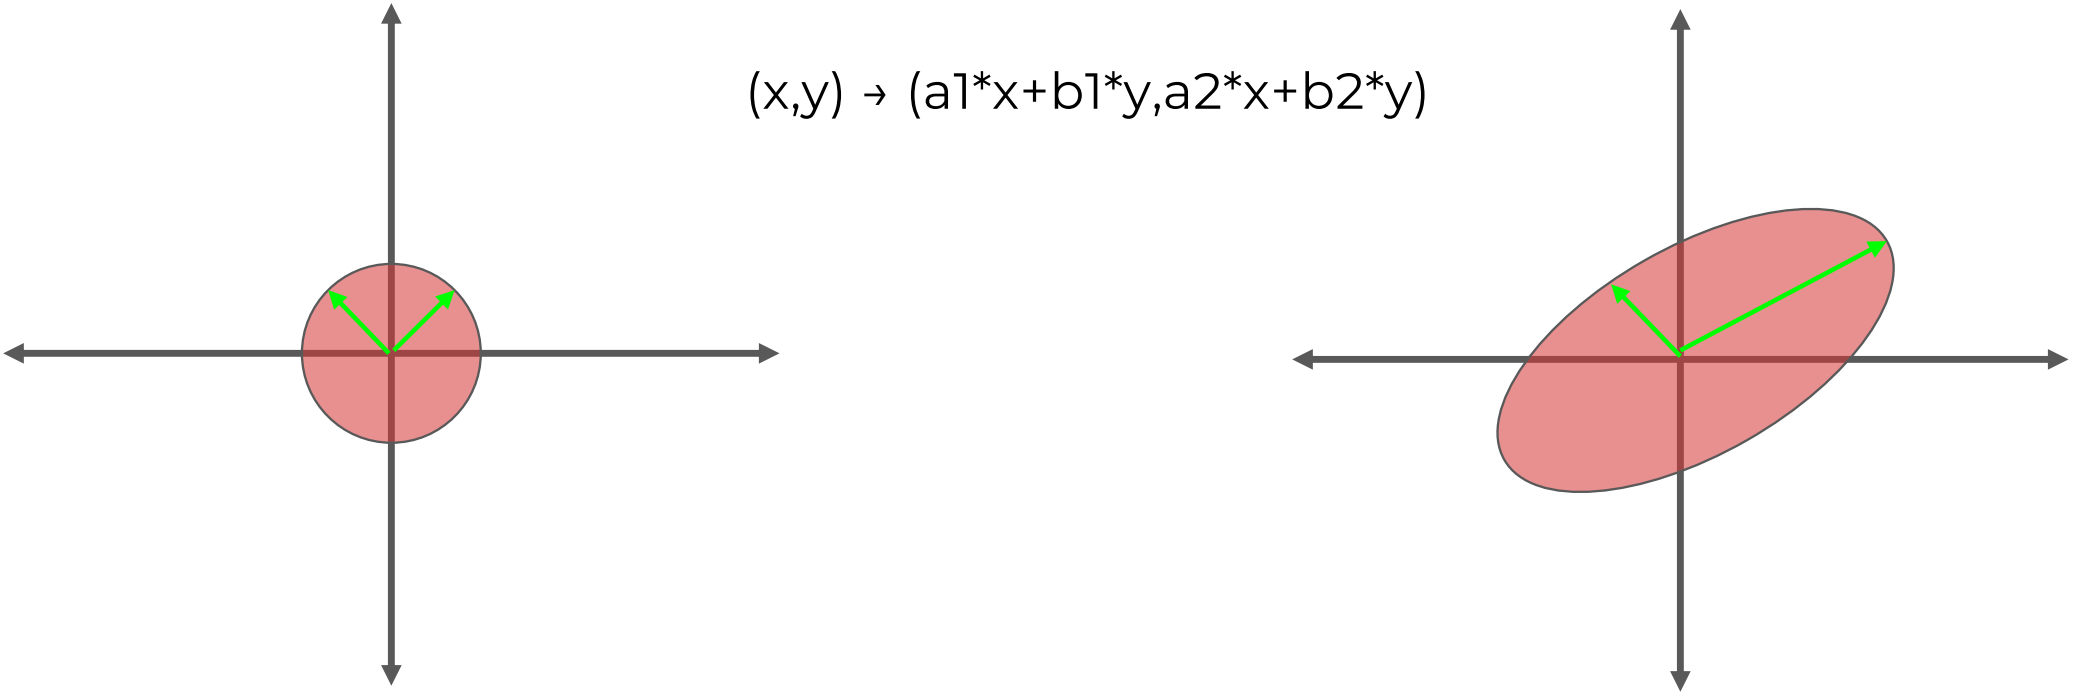

Метод главных компонент

- Собственный вектор это линейное преобразование

(x,y) → (a1*x+b1*y,a2*x+b2*y)

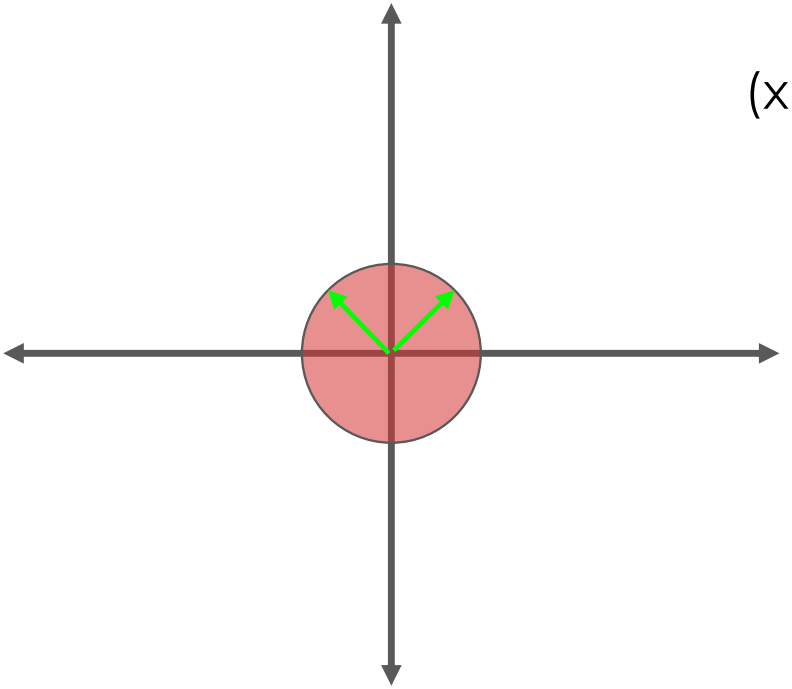

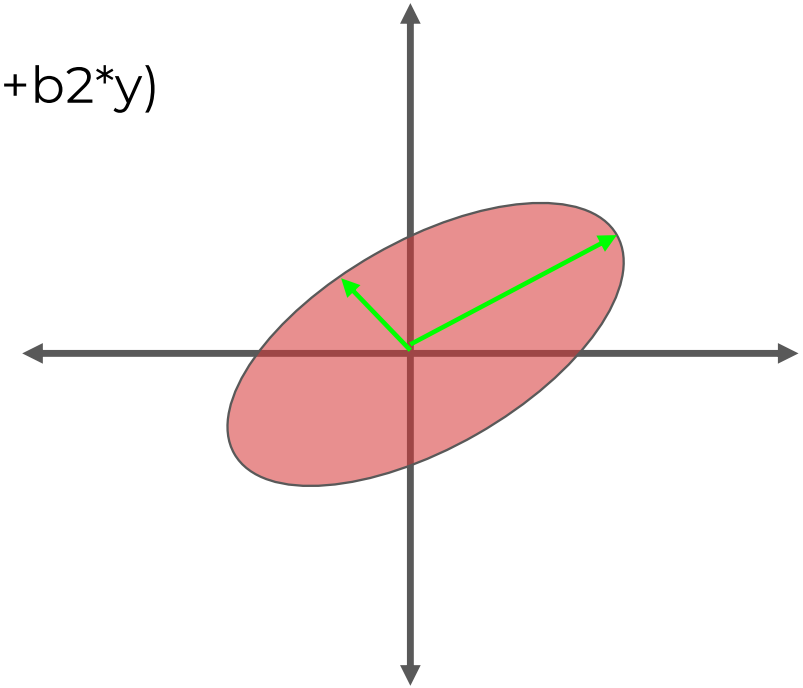

Метод главных компонент

- Выполняем линейное преобразование

$$\begin{bmatrix} \mathrm{Var}(X) & \mathrm{Cov}(X,Y) \\ \mathrm{Cov}(X,Y) & \mathrm{Var}(Y) \end{bmatrix}$$

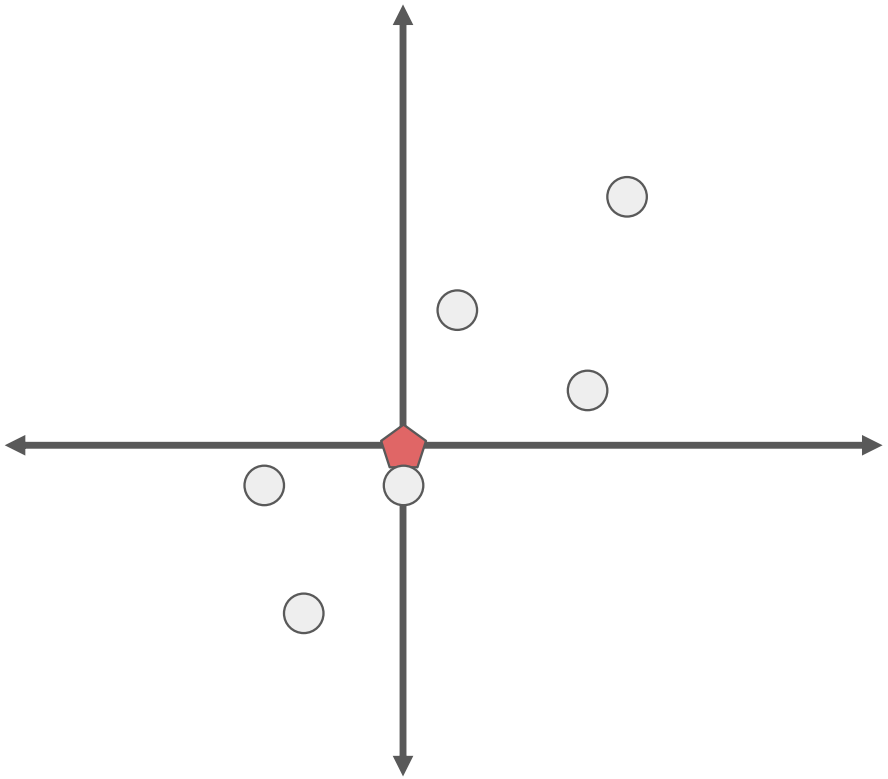

Метод главных компонент

- Выполняем линейное преобразование

$$\begin{bmatrix} \mathrm{Var}(X) & \mathrm{Cov}(X,Y) \\ \mathrm{Cov}(X,Y) & \mathrm{Var}(Y) \end{bmatrix}$$

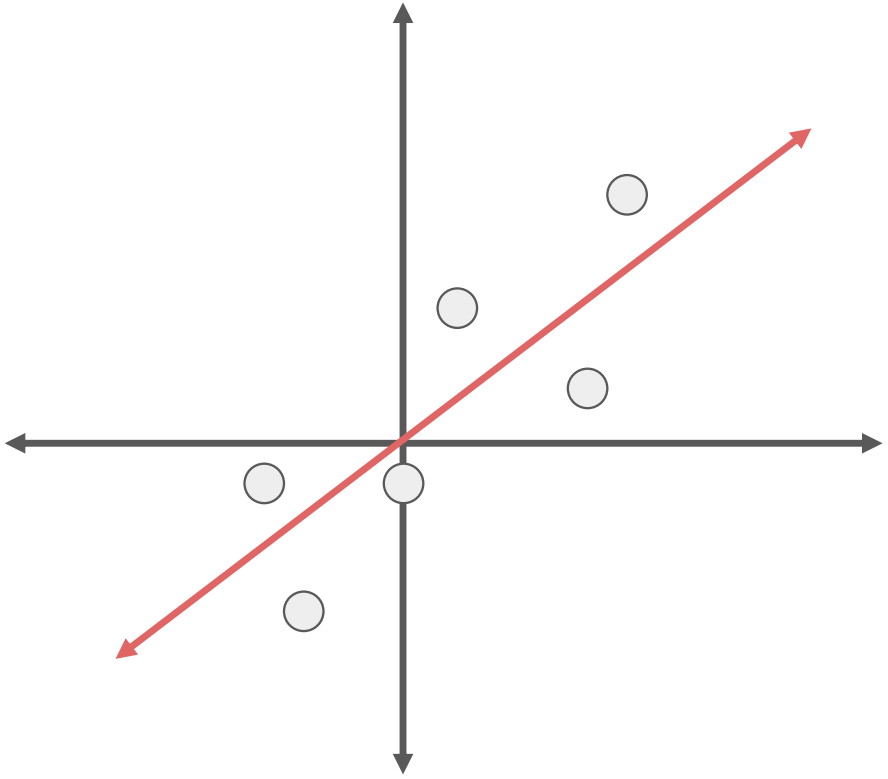

Метод главных компонент

- Выполняем линейное преобразование

$$\begin{bmatrix} \mathrm{Var}(X) & \mathrm{Cov}(X,Y) \\ \mathrm{Cov}(X,Y) & \mathrm{Var}(Y) \end{bmatrix}$$

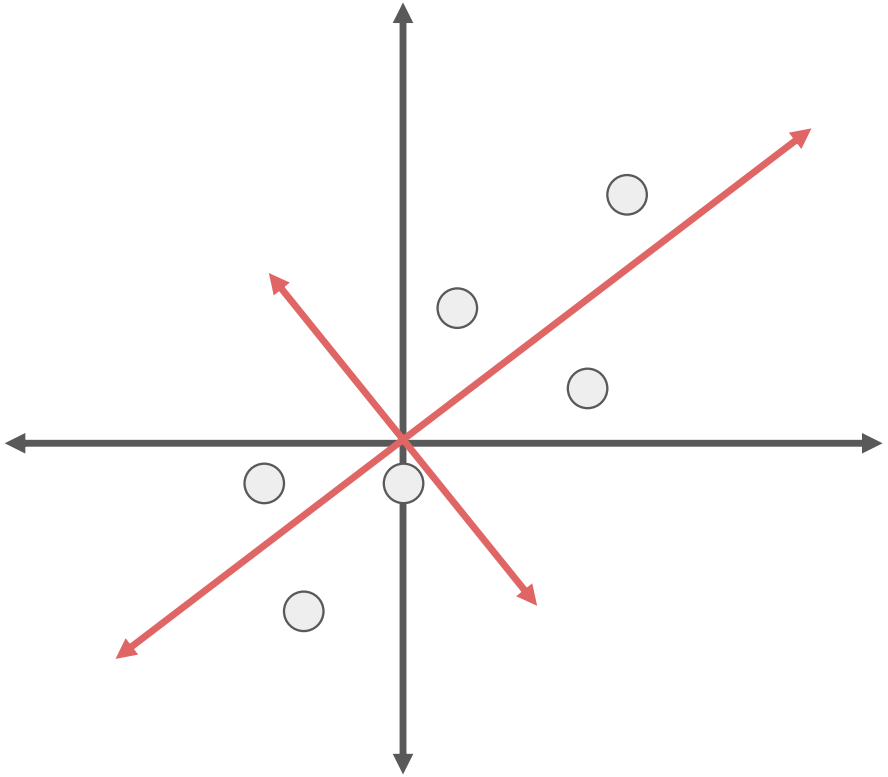

Метод главных компонент

- Собственное значение измеряет объяснение вариативности

$$\begin{bmatrix} \mathrm{Var}(X) & \mathrm{Cov}(X,Y) \\ \mathrm{Cov}(X,Y) & \mathrm{Var}(Y) \end{bmatrix}$$

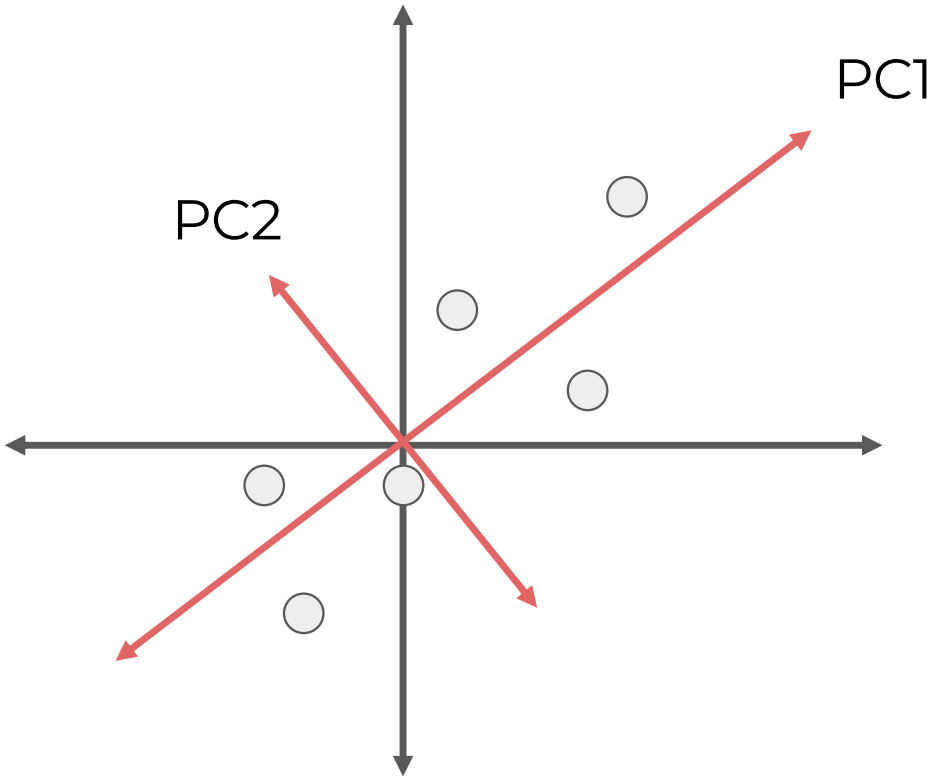

Метод главных компонент

- Собственное значение измеряет объяснение вариативности

$$\begin{bmatrix} \mathrm{Var}(X) & \mathrm{Cov}(X,Y) \\ \mathrm{Cov}(X,Y) & \mathrm{Var}(Y) \end{bmatrix}$$

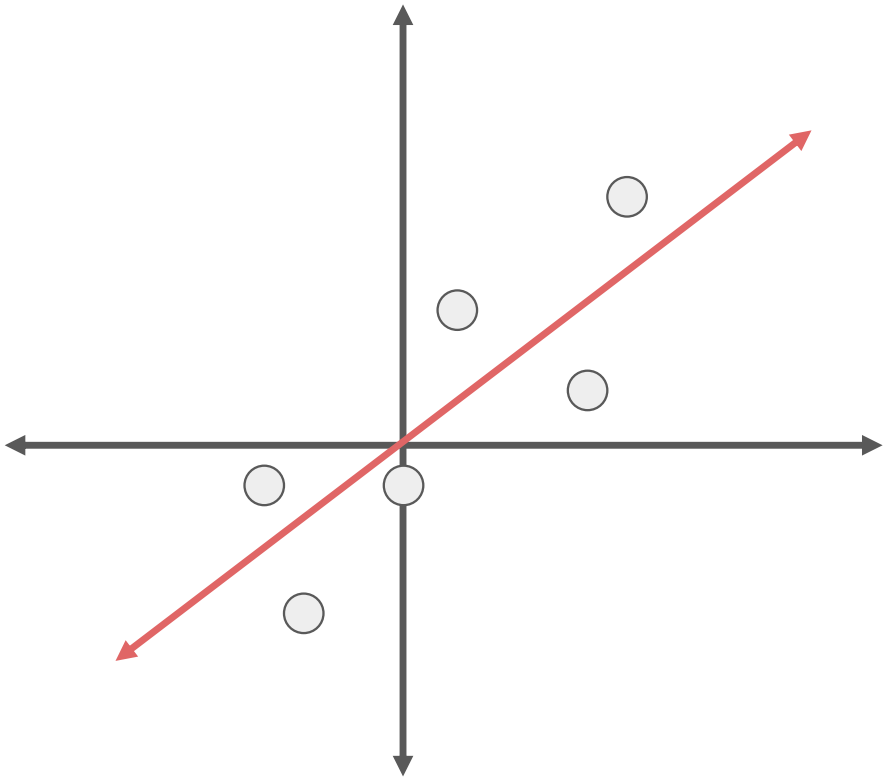

Метод главных компонент

- Собственное значение измеряет объяснение вариативности

$$\begin{bmatrix} \mathrm{Var}(X) & \mathrm{Cov}(X,Y) \\ \mathrm{Cov}(X,Y) & \mathrm{Var}(Y) \end{bmatrix}$$

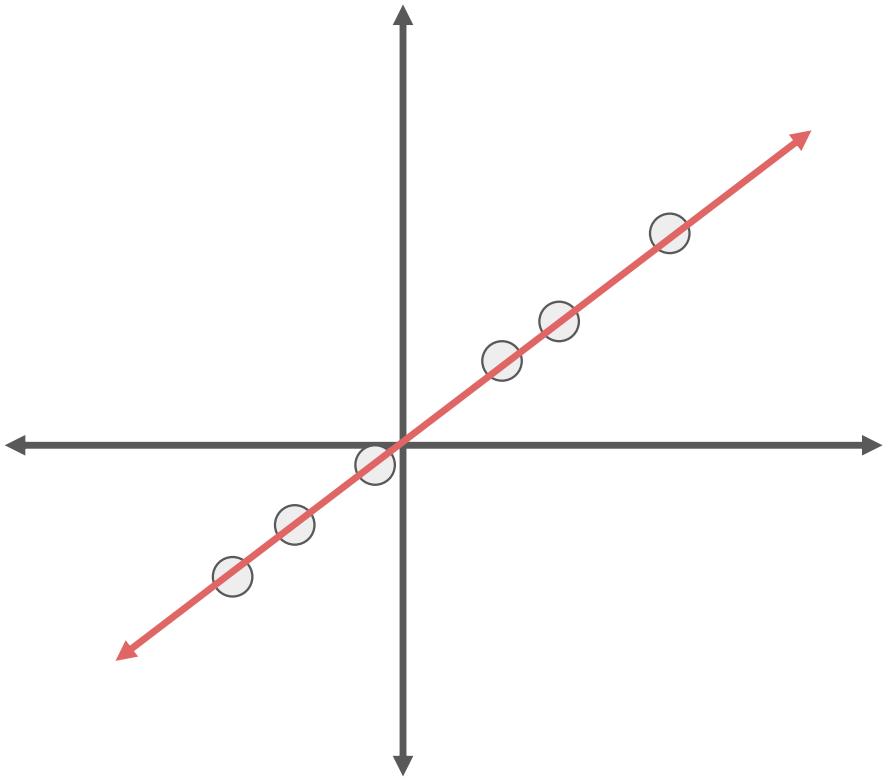

Метод главных компонент

- Собственное значение измеряет объяснение вариативности

$$\begin{bmatrix} \mathrm{Var}(X) & \mathrm{Cov}(X,Y) \\ \mathrm{Cov}(X,Y) & \mathrm{Var}(Y) \end{bmatrix}$$

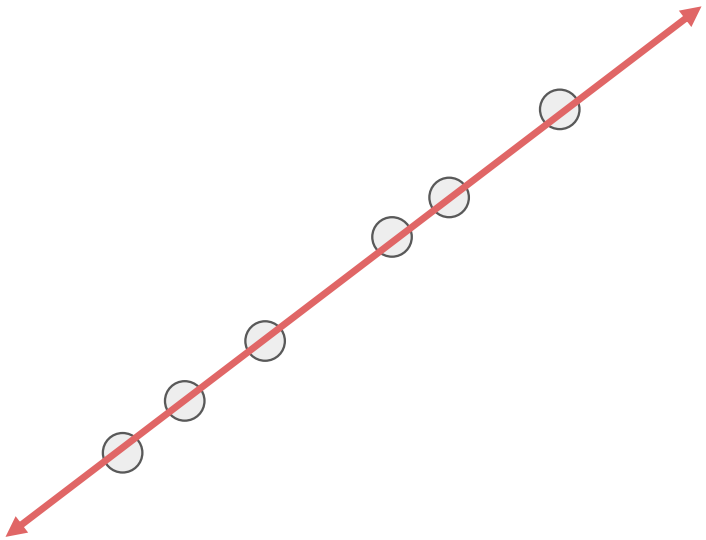

Метод главных компонент

- Собственное значение измеряет объяснение вариативности

$$\begin{bmatrix} \mathrm{Var}(X) & \mathrm{Cov}(X,Y) \\ \mathrm{Cov}(X,Y) & \mathrm{Var}(Y) \end{bmatrix}$$

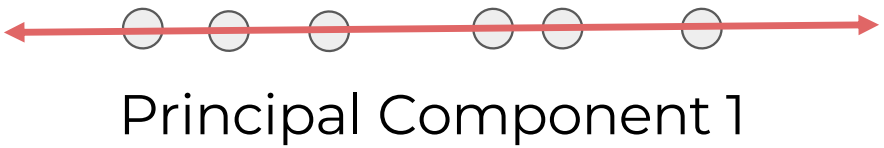

Метод главных компонент

- Шаги метода главных компонент
  - Берём исходные данные
  - Вычисляем ковариационную матрицу
  - Вычисляем собственные вектора (EigenVectors)
  - Сортируем их по собственным значениям
  - Берём N наибольших собственных значений
  - Проецируем данные на собственные вектора

Метод главных компонент

Ручная реализация

PIERIAN DATA

Метод главных компонент

Используем Scikit-Learn

PIERIAN DATA

Метод главных компонент

Обзор проверочных заданий

PIERIAN DATA

Метод главных компонент

Решения

PIERIAN DATA